

Domande teoria esame

1. VM e trigger

1) Analisi delle query (semplificata)

Identificare per ogni query:

WHERE <attributi di select>, <attributi di where>

GB <attributi di group by>, <attributi di partition by>

Aggr <aggregati>

2) Creazione della vista

[...]

SELECT <attributo>, ..., <attributo>, ..., <aggregato> AS <NomeAggr>, ...

FROM <lista tabelle attributi>

WHERE <cond. join>

GROUP BY <attributo>, ..., <attributo>

3) **Identificatore**: attributi nella select, se stessa dimensione scegliere solo quelli con granularità **bassa** (es. Mese → Anno, si sceglie solo Mese)

4) Creazione del trigger

CREATE OR REPLACE TRIGGER <NomeTrigger>

AFTER <INSERT,UPDATE,DELETE> ON <Tabella>

FOR EACH ROW

DECLARE

<Var temporali> DATE;

<Var stringhe> VARCHAR(<n>);

<Var numeriche> NUMBER;

<Var booleane> BOOLEAN;

...Per INSERT e DELETE

N NUMBER;

BEGIN

...Se INSERT

...Dai codici agli attributi

SELECT <attributi> INTO <variabili>

FROM <tabella attributi>

WHERE <CodAttr> = :NEW.<CodAttr>;

SELECT COUNT(*) INTO N

FROM <NomeVista>

WHERE <join su identificatore>;

IF N>0 THEN

...Esiste già, quindi update

```

UPDATE <NomeVista>
SET <aggiornamento aggregati>
WHERE <identificatore>;
ELSE
...Non esiste, quindi insert
  INSERT INTO <NomeVista>(<attributi nella select della vista con stesso ordine>)
  VALUES (<variabile>, ..., :NEW.<aggregato>, ...);
END IF;

```

...Se UPDATE

```

...N non serve
UPDATE <NomeVista>
SET <aggiornamento aggregati>
WHERE <identificatore>;

```

...Se DELETE

```

...Come INSERT ma con :OLD invece che :NEW
...La sintassi per la DELETE è:
IF N>0 THEN
DELETE FROM <NomeVista>
WHERE <identificatore>

END;

```


2. Data preprocessing

Distanza di Manhattan

$$d(i, j) = \sum_{k=1}^n |x_{ik} - y_{jk}|$$

Correlazione di Pearson

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$



Scatter plots showing the similarity from -1 to 1 .

Perfect linear correlation when value is 1 or -1

09/02/2022

Teoria - 1 punto (penalità 15% per risposta sbagliata)

La correlazione di Pearson fra due variabili $X = \{x_1, x_2, \dots, x_n\}$ con media $\bar{x}$ e $Y = \{y_1, y_2, \dots, y_n\}$ con media $\bar{y}$ viene definita come:

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Un dataset è costituito da cinque features A, B, C, D, E. Si considerino i seguenti valori di correlazione tra le features, espressi attraverso il coefficiente di Pearson:

- $\text{corr}(A, B) = -1$
- $\text{corr}(B, C) = 0.4$
- $\text{corr}(C, D) = 1$
- $\text{corr}(D, E) = -0.3$

Quale delle seguenti affermazioni **non** è corretta:

- ☐ (a) quando la variabile C cresce, anche la variabile D cresce
- ☐ (b) $\text{corr}(C, E) = -0.3$
- ☐ (c) $\text{corr}(A, C) = 0.4$
- ☐ (d) le variabili A e B potrebbero contenere i seguenti valori: $A = [5, 6, 7, 8]$, $B = [-5, -6, -7, -8]$
- ☐ (e) le variabili C e D potrebbero contenere i seguenti valori: $C = [1, 2, 3, 4]$, $D = [1, 3, 5, 7]$
- ☐ (f) le variabili C e D potrebbero contenere valori identici

Risposta: c

(<https://chatgpt.com/c/6787cb59-18fc-8000-8bd8-20a500fa3428>) la query su chatgpt

La correlazione tra a e c non può essere determinata direttamente solo conoscendo le correlazioni $\text{corr}(a,b)$ e $\text{corr}(b,c)$. Questo perché la correlazione non soddisfa una proprietà transitiva diretta (cioè $\text{corr}(a,c) \neq \text{corr}(a,b) \cdot \text{corr}(b,c)$).

Tuttavia, ci sono alcune situazioni particolari in cui si può fare un'ipotesi sulla correlazione tra a e c, ma queste dipendono da ulteriori informazioni sulla relazione tra a, b e c, come:

1. **Linearità e dipendenza perfetta:** Se i tre punti sono perfettamente allineati linearmente, si potrebbe derivare una relazione diretta tra a e c. Questo caso, però, è raro.
2. **Indipendenza condizionale:** Se si sa che a, b, e c formano una catena causale (ad esempio $a \rightarrow b \rightarrow c$) e le correlazioni date riflettono tali relazioni, è possibile fare un'ipotesi più precisa, ma non garantisce una formula semplice.

Se ipotizzi che la correlazione sia influenzata solo dai valori dati e che ci sia una struttura lineare sottostante, potresti tentare un'approssimazione come:

$$\text{corr}(a,c) \approx \text{corr}(a,b) \cdot \text{corr}(b,c)$$

Nel nostro caso possiamo trovare la correlazione tra a e c perché a e b sono direttamente proporzionali ($\text{corr}(a,b) = 1$).

09/02/2022

Teoria - 1 punto (penalità 15% per risposta sbagliata)

La correlazione di Pearson fra due variabili $x = \{x_1, x_2, \dots, x_n\}$ con media $\bar{x}$ e $y = \{y_1, y_2, \dots, y_n\}$ con media $\bar{y}$ viene definita come:

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Un dataset è costituito da cinque features A, B, C, D, E. Si considerino i seguenti valori di correlazione tra le features, espressi attraverso il coefficiente di Pearson:

- $\text{corr}(A, B) = 1$
- $\text{corr}(B, C) = 0.2$
- $\text{corr}(C, D) = -1$
- $\text{corr}(D, E) = -0.7$

Quale delle seguenti affermazioni **non** è corretta:

Scegli un'alternativa:

- ☐ a. $\text{corr}(C, E) = 0.7$
- ☐ b. le variabili A e B contengono necessariamente valori identici
- ☐ c. quando la variabile C cresce, la variabile D decresce
- ☐ d. $\text{corr}(A, C) = 0.2$
- ☐ e. tra C e D esiste una correlazione lineare
- ☐ f. la variabile con cui C è maggiormente correlata linearmente è D

Risposta: b

Sono direttamente proporzionali, non per forza identici.

3. Regole di associazione

Associazione “if-then”

20/01/2025

**Domanda
10**

Risposta
corretta

Punteggio
ottenuto 1,50
su 1,50

1.5 punto (-15% di penalità per ogni risposta sbagliata)

Viene fornito un classificatore basato su regole con le seguenti regole per la classificazione degli animali:

1. If Habitat = Acqua, then Classe = Pesce.
2. If Habitat = Acqua and Numero di zampe > 6, then Classe = Crostaceo.
3. If Numero di zampe >= 2, then Classe = Mammifero.
4. If Numero di zampe = 8, then Classe = Aracnide.
5. If Può volare = Sì, then Classe = Uccello.
6. If Habitat = Acqua and Numero di zampe = 4, then Classe = Anfibia.

Si incontra un nuovo animale con questi attributi:

- Habitat: Terra
- Numero di zampe: 4

- Può volare: No

A quale classe sarà assegnato questo animale?

- ☐ a. Nessuna risposta è corretta
- ☐ b. Anfibia
- ☒ c. Mammifero ✓
- ☐ d. Pesce
- ☐ e. Uccello
- ☐ f. Aracnide
- ☐ g. Crostaceo

Risposta corretta.

La risposta corretta è:
Mammifero

Un semplice “if then”, hai degli attributi e li confronti in ordine con tutte le regole presenti all’inizio. L’habitat datoci è Terra quindi escludiamo i primi 2, il nostro animale ha 4 zampe che sono maggiori di 2 quindi la terza regola è soddisfatta, dunque è un Mammifero.

Confidenza e Supporto

Data una regola di associazione $A \Rightarrow B$ con A e B definiti itemset

- Supporto
 - Frazione delle transazioni che contengono sia A che B
 - $\text{supp}(A,B) = \frac{\# \{A,B\}}{\# \text{tuple transaz.}}$

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

- Commutativo se nello stesso set: $\text{supp}(A,B)=\text{supp}(B,A)$ con A,B nello stesso set
- Confidenza
 - Frazione di transazioni che contengono B nelle transazioni che contengono A
 - “Forza” della $\Rightarrow$
 - $\text{conf}(A)=\text{supp}(A,B)/\text{supp}(A)=\# \{A,B\}/\# \{A\}$
 - NON commutativa

13/09/2021

1 punto (-15% per risposta errata)

A partire dal set di transazioni riportate in tabella, sono date le due seguenti regole:

R1: Uova $\Rightarrow$ Zucchero

R2: Zucchero $\Rightarrow$ Uova

TID	ITEMS
1	Latte, Pane, Uova, Zucchero
2	Birra, Pane
3	Birra, Latte, Zucchero
4	Birra, Pane, Uova, Zucchero
5	Uova, Zucchero
6	Latte, Pane, Uova

Quale delle seguenti affermazioni **non** è corretta?

Scegli un'alternativa:

- ☐ a. Poiché sono derivate dallo stesso itemset, le due regole R1 e R2 hanno necessariamente la stessa confidenza
- ☐ b. Poiché sono derivate dallo stesso itemset, le due regole R1 e R2 hanno necessariamente lo stesso supporto
- ☐ c. Il supporto della regola R1 è pari al 50%
- ☐ d. Le due regole R1 e R2 hanno lo stesso supporto
- ☐ e. Le due regole R1 e R2 hanno la stessa confidenza
- ☐ f. La confidenza della regola R2 è pari al 75%

$$\text{supp}(R1)=3/6=1/2=\text{supp}(R2)$$

$$\text{conf}(Uova)=3/4=0.75$$

$$\text{Conf}(Zucchero)=3/4=0.75$$

In questo caso le due confidenze coincidono.

Risposta: a

Apriori

Per ogni livello:

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

- **join step:** generare candidati di lunghezza $k + 1$ unendo gli itemset frequenti di lunghezza k che hanno la parte iniziale lunga $k - 1$ in comune
- **prune step:** eliminare i candidati di lunghezza $k + 1$ che contengono **almeno** un k -itemset che non è frequente
- Calcolare il supporto dei candidati $k + 1$ e eliminare quelli sotto la soglia minsup

Strategia: non dovete fare un albero quindi appena il valore supera il minsup non contate tutte le occorrenze. Leggete bene le domande: a volte vuole solo sapere gli elementi eliminati dal minsup, a volte quelli dal prune (passo precedente all'eliminazione minsup)

26/01/2021

Teoria (Frequent itemsets) (2 punti, -15% penalità per risposta sbagliata)

Il principio Apriori afferma che se un itemset è frequente, tutti i suoi subset devono essere frequenti.

È dato il seguente dataset transazionale.


A C E
A B C D
C D
A C D
A B
A B E
B C E
A D E
A B E
A C D E

Si vuole applicare l'algoritmo Apriori per l'estrazione degli itemset frequenti con minsup = 2 (un itemset è frequente se compare in almeno 2 transazioni).

Durante la generazione degli itemset candidati di lunghezza 3, dopo il "prune step" effettuato applicando il principio Apriori, quanti candidati sono selezionati per il conteggio del supporto nel dataset?

Scegli un'alternativa:

- ☐ a. 9
☐ b. 4
☐ c. 7
☐ d. 6
☐ e. 5
☐ f. 8



B,C e B,D vengono eliminati perché minori del minsup.

03/07/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Dato il seguente dataset di transazioni:

- {A, C}
- {B, D, E}
- {A, B, D, E}
- {C, D}
- {A, B, C, E}
- {A, D}
- {B, C, D, E}
- {A, B, C, D, E}
- {C, E}

Applicare l'algoritmo APriori con $\text{minsup} > 3$ (un itemset è frequente se compare in più di 3 transazioni). Quali sono gli itemset di lunghezza 2 che vengono generati da Apriori dopo i passi di join e prune (con principio Apriori), prima del conteggio del supporto nella base dati?

Scegli un'alternativa:

- ☐ a. A-B, A-C, A-D, A-E, B-C, B-D, B-E, C-D, C-E, D-E
- ☐ b. B-D, B-E, C-D, C-E, D-E
- ☐ c. Nessuna delle precedenti
- ☐ d. B-C, B-D, B-E, C-D, C-E, D-E
- ☐ e. B-E
- ☐ f. B-D, B-E, C-E, D-E
- ☐ g. A-B, A-D, A-E, B-C, B-D, B-E, C-D, C-E, D-E
- ☐ h. A-B, A-C, A-D, A-E, B-C, B-E, C-D, C-E, D-E

{A, C}

{B, D, E}

{A, B, D, E}

{C, D}

{A, B, C, E}

{A, D}

{B, C, D, E}

{A, B, C, D, E}

{C, E}

$\text{minsup} > 3$

A : 5

B : 5

C : 6

D : 5

E : 6

AB

AC

AD

AE

BC

BD

BE

CD

CE

DE

Risposta: a

FP-growth

Fasi (2 letture del database)

- Conteggio dei supporti ed eliminazione degli item al di sotto del minsup
- Costruzione della Header Table: gli item vengono ordinati in ordine di supporto decrescente
- Creazione del FP-tree: per ogni transazione ordinare gli oggetti in ordine di supporto decrescente ($\rightarrow$ Header Table) e inserirli all'interno dell'albero creando un nuovo ramo quando la sequenza di oggetti cambia

- Per trovare il Conditional Pattern Base per l'elemento i (i-CPB) selezionare i percorsi relativi ai prefissi di i dal FP-tree, il supporto è pari al supporto di i nel ramo

09/02/2022

Teoria - 2 punti (penalità 15% per ogni risposta sbagliata)

Si consideri la seguente base dati transazionale.


ABCD
BCE
ABDE
BCDE
BCDE
BCD
E
BD
BD
ABDE

Si applichi l'algoritmo FP-growth per l'estrazione degli itemset frequenti (minsup = 2; un itemset è frequente se compare in almeno 2 transazioni).

Quali sono i pattern contenuti all'interno del C-CPB (C Conditional Pattern Base)? Selezionare *tutti e soli* i pattern corretti, insieme ai loro supporti.

Scegli una o più alternative:

- ☐ a. BD: 2
- ☐ b. E: 3
- ☐ c. BDE: 4
- ☐ d. B: 5
- ☐ e. E: 2
- ☐ f. BE: 3
- ☐ g. D: 3
- ☐ h. BD: 8
- ☐ i. B: 1
- ☐ j. BDE: 2
- ☐ k. BE: 1
- ☐ l. D: 4



Risposte: a, j, k

22/02/2024

1.5 punti (-15% di penalità per ogni risposta sbagliata)

Sono date le seguenti transazioni:

E, B, C, D
B, E
B, A
C, E
B, E, D
F, A, E, D, B, C
B, E, A, F, D, C
C, B
E, D, A, B, F
F, D, A, B, E

Si crei un FP-Tree con $\text{MinSup} > 3$ (un itemset è frequente se compare in più di 3 transazioni) per le transazioni precedenti. In caso di item con uguale supporto, utilizzare l'ordine lessicografico (per es. se $A = 2$ e $B = 2$, A precede B).

Indicare il pattern e il rispettivo supporto contenuti nel C-CPB (C Conditional Pattern Base).

Le risposte sono nel formato *Pattern:Supporto*.

Scegli un'alternativa:

- ☐ a. Nessuna risposta è corretta
- ☐ b. B: 2
- ☐ c. A, B: 1
- ☐ d. D, E, B: 2
- ☒ e. D, E, B: 1 ✓
- ☐ f. D, E, B: 3
- ☐ g. A, D, E, B: 1
- ☐ h. E: 2

C-CPB:

$\{B\} = 1$

$\{B, E, D\} = 1$

$\{B, E, D, A\} = 2$

$\{E\} = 1$

Risposta: e

20/09/2024

2 punto (-15% di penalità per ogni risposta sbagliata)

Sono date le seguenti transazioni:

1. A, C, D, E
2. B, C, E
3. B, C
4. D, E
5. B, D
6. A, C, D, E
7. B, C, D
8. A, E
9. C, D, E
10. A, B, C, E

Si costruisca un **FP-Tree** a partire dalle transazioni elencate, utilizzando un **MinSup > 2**. Un itemset è considerato frequente se appare in più di 2 transazioni.

In caso di item con supporto uguale, si utilizzi l'ordine lessicografico (ad esempio, se $A = 3$ e $B = 3$, A precede B).

Dopo aver costruito l'albero FP-Tree, si identifichino i pattern e i relativi supporti presenti nella **B-CPB (B Conditional Pattern Base)**.

Il supporto degli itemset deve essere indicato nella forma **Pattern: Supporto**.

Scegli un'alternativa:

- ☐ a. C, D: 2
- ☐ b. Nessuna risposta è corretta
- ☐ c. C, E: 1
- ☐ d. D: 2
- ☒ e. C, E: 2 ✓
- ☐ f. C, D: 3
- ☐ g. D, E, C: 3
- ☐ h. C: 2

B-CPB:

$\{C\} = 1$

$\{C,E\} = 2$

$\{C,D\} = 1$

$\{D\}=1$

Risposta: e

20/01/2025

2 points (-15% penalty for each wrong answer)

The following transactions are given:

1. A, B, C, D
2. A, B, C, E
3. B, C, D
4. A, B, D, E, F
5. A, B, C, D, E, F
6. B, C, D, E, F
7. A, B, E
8. A, B, C, D, E, F
9. A, B, C, D
10. A, B, C, D, E, F

Construct an **FP-Tree** from the listed transactions, using a **MinSup** ≥ 2 . An itemset is considered frequent if it appears in at least 2 transactions.

In case of items with equal support, lexicographic order is used (e.g., if items A and B have the same support, then A precedes B).

After constructing the FP-Tree, identify the patterns and their supports present in the **FE-CPB** (FE Conditional Pattern Base). Which of the following sets of **Pattern: Support** pairs is the FE-CPB? (Where pattern is a set of items).

- ☐ a. {DCAB: 3, DAB: 1}
- ☐ b. {BD: 5}
- ☐ c. {DCAB: 3, DAB: 1, DCB: 1, CAB: 1}
- ☐ d. {DCAB: 3, DAB: 1, CAB: 1}
- ☐ e. No answer is correct
- ☐ f. {DCAB: 3, DAB: 1, DCB: 1, AB: 1}

- ☐ g. {DCAB: 3, DAB: 1, AB: 1}

Per risolvere l'esercizio è necessario creare l'FP-Tree rispetto alla soglia di minsup pari a 2. Successivamente, estrarre dall'FP-Tree i pattern che contengono FE.

Creiamo la Header Table: scandiamo la base dati transazionale e assegnamo ad ogni item il rispettivo valore di supporto.

A	8
B	10
C	8
D	8
E	7
F	5

In questo caso, tutti gli item sono frequenti.


Ora bisogna ordinare la header table sulla base del supporto decrescente degli item.



Header Table:

B	10
A	8
C	8
D	8
E	7
F	5

Ogni transazione va ordinata sulla base dell'ordinamento della Header Table, creando l'FP-Tree.



1. B, A, C, D
2. B, A, C, E
3. B, C, D
4. B, A, D, E, F
5. B, A, C, D, E, F
6. B, C, D, E, F
7. B, A, E
8. B, A, C, D, E, F
9. B, A, C, D
10. B, A, C, D, E, F


1) B, A, C, D	
---------------	---

2) B, A, C, E	 <pre> graph TD Root["{}"] --> B2 B2 --> A2 A2 --> C2 C2 --> D1 C2 --> E1 </pre>
3) B, C, D	 <pre> graph TD Root["{}"] --> B3 B3 --> A2 B3 --> C1 A2 --> C2 C2 --> D1 C2 --> E1 C1 --> D1 </pre>

4) B, A, D, E, F	<pre> graph TD Root["{}"] --> B4["B4"] B4 --> A3["A3"] B4 --> C1["C1"] A3 --> C2["C2"] A3 --> D1_1["D1"] C2 --> D1_2["D1"] C2 --> E1_1["E1"] D1_1 --> E1_2["E1"] E1_1 --> F1_1["F1"] C1 --> D1_3["D1"] D1_3 --> F1_2["F1"] </pre>
5) B, A, C, D, E, F	<pre> graph TD Root["{}"] --> B5["B5"] B5 --> A4["A4"] B5 --> C1["C1"] A4 --> C3["C3"] A4 --> D1_1["D1"] C3 --> D2["D2"] C3 --> E1_1["E1"] D2 --> E1_2["E1"] E1_1 --> F1_1["F1"] C1 --> D1_2["D1"] D1_2 --> F1_2["F1"] </pre>

6) B, C, D, E, F	<pre> graph TD Root["{}"] --> B6["B6"] B6 --> A4["A4"] B6 --> C2["C2"] A4 --> C3["C3"] A4 --> D1["D1"] C3 --> D2["D2"] C3 --> E1_1["E1"] D1 --> E1_2["E1"] D1 --> F1_1["F1"] D2 --> E1_3["E1"] E1_1 --> F1_2["F1"] E1_2 --> F1_3["F1"] E1_3 --> F1_4["F1"] C2 --> D2_1["D2"] D2_1 --> E1_4["E1"] E1_4 --> F1_5["F1"] </pre>
7) B, A, E	<pre> graph TD Root["{}"] --> B7["B7"] B7 --> A5["A5"] B7 --> C2["C2"] A5 --> C3["C3"] A5 --> D1["D1"] A5 --> E1_1["E1"] C3 --> D2["D2"] C3 --> E1_2["E1"] D1 --> E1_3["E1"] D1 --> F1_1["F1"] E1_1 --> F1_2["F1"] D2 --> E1_4["E1"] E1_2 --> F1_3["F1"] E1_3 --> F1_4["F1"] C2 --> D2_1["D2"] D2_1 --> E1_5["E1"] E1_5 --> F1_5["F1"] </pre>

8) B, A, C, D, E, F	 <pre> graph TD Root["{}"] --> B8["B8"] B8 --> A6["A6"] B8 --> C2["C2"] A6 --> C4["C4"] A6 --> D1["D1"] A6 --> E1_1["E1"] C4 --> D3["D3"] C4 --> E1_2["E1"] D1 --> E1_3["E1"] D1 --> F1_1["F1"] E1_1 --> F1_2["F1"] C2 --> D2["D2"] C2 --> E1_4["E1"] D2 --> E1_5["E1"] D2 --> F1_3["F1"] E1_4 --> F1_4["F1"] D3 --> F2["F2"] E1_2 --> F1_5["F1"] E1_3 --> F1_6["F1"] E1_5 --> F1_7["F1"] E1_4 --> F1_8["F1"] </pre>
9) B, A, C, D	 <pre> graph TD Root["{}"] --> B9["B9"] B9 --> A7["A7"] B9 --> C2["C2"] A7 --> C5["C5"] A7 --> D1["D1"] A7 --> E1_1["E1"] C5 --> D4["D4"] C5 --> E1_2["E1"] D1 --> E1_3["E1"] D1 --> F1_1["F1"] E1_1 --> F1_2["F1"] C2 --> D2["D2"] C2 --> E1_4["E1"] D2 --> E1_5["E1"] D2 --> F1_3["F1"] E1_4 --> F1_4["F1"] D4 --> F2["F2"] E1_2 --> F1_5["F1"] E1_3 --> F1_6["F1"] E1_5 --> F1_7["F1"] E1_4 --> F1_8["F1"] </pre>



Verifica: la somma dei supporti locali deve essere pari al supporto globale.

$B = 10$ ✓

$A = 8$ ✓


$C = 6 + 2 = 8$ ✓

$D = 5 + 1 + 2 = 8$ ✓

$E = 3 + 1 + 1 + 1 + 1 = 7$ ✓

$F = 3 + 1 + 1 = 5$ ✓

Ora bisogna trovare i pattern contenuti all'interno di F-CPB: dalla Header Table, generiamo la node-link chain, che ci permette di raggiungere i path dell'albero.



Accediamo alla Header Table sul nodo F, estraendo il primo pattern di F. Leggo il prefisso di F con il supporto di F, senza il nodo F.

1. B, A, C, D, E 3
2. B, A, D, E 1
3. B, C, D, E 1

F-CPB contiene 3 pattern.

Ripeto la procedura da capo, considerando i rispettivi supporti, come se questi pattern costituissero una nuova base dati transazionale.

Header Table

B	5 (3 + 1 + 1)
A	4 (3 + 1)


C	$4 (3 + 1)$
D	$5 (3 + 1 + 1)$
E	$5 (3 + 1 + 1)$

Ordinamento decrescente:

B	5
D	5
E	5
A	4
C	4

1) B, D, E, A, C 3	$\{ \}$ B3 D3 E3 A3 C3
2) B, D, E, A 1	$\{ \}$ B4 D4 E4 A4 C3

3) B, D, E, C 1



Verifica: la somma dei supporti locali deve essere pari al supporto globale.

B = 5 ✓


D = 5 ✓

E = 5 ✓

A = 4 ✓

C = 3 + 1 = 4 ✓

Infine, trovo i pattern contenuti all'interno di FE-CPB.




FE-CPB = {B, D}


Itemset frequenti

Un itemset frequente è

- **closed** se nessuno dei suoi superset adiacenti ha lo stesso supporto dell'itemset
- **massimale** se nessuno dei suoi superset adiacenti è frequente



Suggerimento: disegnare parte del seguente grafo e scegliere la risposta corretta andando per esclusione



11/09/2023

1.5 punti (15% di penalità per una risposta sbagliata)

Un itemset frequente e' massimale se nessuno dei suoi superset e' frequente.

Dopo aver estratto gli itemset frequenti da un dataset, vengono estratti gli itemset frequenti massimali.

Tra gli altri itemset massimali, vi sono i seguenti:

bce
bd
abe

Quale delle seguenti conclusioni puo' essere raggiunta, sulla base di queste informazioni?


Scegli un'alternativa:

- ☐ a. L'itemset ace potrebbe essere frequente, invece l'itemset ac non puo' essere frequente
- ☐ b. E' presente piu' di una risposta corretta fra le altre opzioni
- ☐ c. L'itemset ac potrebbe essere frequente, invece l'itemset cde non puo' essere frequente
- ☐ d. L'itemset abd potrebbe essere frequente, invece l'itemset bcd non puo' essere frequente
- ☐ e. L'itemset ac potrebbe essere frequente, invece l'itemset abc non puo' essere frequente
- ☐ f. L'itemset acd potrebbe essere frequente, invece l'itemset abd non puo' essere frequente
- ☐ g. Nessuna delle altre opzioni e' corretta
- ☐ h. L'itemset bde potrebbe essere frequente, invece l'itemset bcd non puo' essere frequente
- ☐ i. L'itemset cde potrebbe essere frequente, invece l'itemset de non puo' essere frequente

bce
bd
abe

} Frequenti massimali

in Frequenti



Risposta: f

4. Classificazione

Albero decisionale

1 punto (-15% penalità per risposta sbagliata)

Un albero decisionale viene addestrato su un dataset contenente M punti, P attributi e N classi.

Qual e' il numero massimo di nodi foglia che puo' avere l'albero addestrato?

Scegli un'alternativa:

- ☐ a. Non e' possibile rispondere con le informazioni a disposizione
- ☐ b. Nessuna delle altre risposte e' corretta
- ☐ c. P nodi
- ☐ d. M + N nodi
- ☐ e. M + P nodi
- ☐ f. N nodi
- ☐ g. M nodi
- ☐ h. N + P nodi

Risposta: g

Il numero di foglie dipende dalla capacità del modello di separare i punti. Nel caso peggiore (massima espansione dell'albero), ogni punto del dataset viene isolato in una foglia distinta e quindi esso ha M foglie scollegate tra di loro. Non viene influenzato dal numero di classi anche se $N < M$.

Gini Index

$$GINI(t) = 1 - \sum_j [p(j|t)]^2$$

Con $p(j|t) = \frac{\text{\#elementi di } J}{\text{\#elementi tot}}$ è la frequenza relativa della classe j rispetto al nodo t .

Più l'indice di GINI è piccolo, minore è il grado di impurità.

Quando un nodo è diviso in k figli, la qualità dello split è misurata come:

$$GINI_{split} = \sum_{i=1}^k \frac{n_i}{n} GINI(i)$$

- n_i = numero di record del figlio i
- n = numero di record totali del nodo

20/09/24

1.5 punto (-15% di penalità per ogni risposta sbagliata)

Definizione

Il GINI index di un nodo è 1 meno la somma dei quadrati delle proporzioni delle classi nel nodo.

$$GINI(t) = 1 - \sum_j [p(j|t)]^2$$

dove $p(j | t)$ e' la frequenza relativa (proporzione) della classe j al nodo

Testo

E' dato un nodo genitore che contiene 12 record, 6 dei quali appartengono alla classe C1 e 6 alla classe C2. Dopo uno split sull'attributo B, il nodo genitore viene diviso in due nodi figli N1 e N2 con le seguenti distribuzioni di classe:

- N1: C1 = 5, C2 = 2
- N2: C1 = 1, C2 = 4

Qual è il Gini Index dei figli?

Scegli un'alternativa:

- ☐ a. 0.396
- ☐ b. 0.5
- ☐ c. Nessuna risposta è corretta
- ☐ d. 0.25
- ☐ e. 0.278
- ☐ f. 0.417
- ☐ g. 0.335

Calcolo di $p(Cn/Nn)$

$$p(C1/N1) = 5/(2+5) = 5/7$$

$$p(C2/N1) = 2/7$$

$$p(C1/N2) = 1/5$$

$$p(C2/N2) = 4/5$$

Calcolo di Gini(Nn)

$$Gini(N1) = 1 - (p(C1/N1)^2 + p(C2/N1)^2) = 1 - ((5/7)^2 + (2/7)^2) = 20/49$$

$$Gini(N2) = 1 - (p(C1/N2)^2 + p(C2/N2)^2) = 1 - ((1/5)^2 + (4/5)^2) = 8/25$$

Calcolo del Gini dello split

$$tot = C1(N1)+C2(N1)+C1(N2)+C2(N2) = 12$$

$$Gini = Gini(N1) * N1/tot + Gini(N2) * N2/tot = 13/35$$

Risposta: g (sbagliata, viene 13/35, circa 0,371)

ReLu

$$(\sum(x_i * w_i)) + b$$

03/07/24

1 punto (-15% di penalità per ogni risposta sbagliata)


Un neurone riceve in input il seguente vettore:

$x = [1, 0, 1, 1, 0, 1, 1, 0]$

Il neurone ha il seguente vettore w di pesi e il seguente bias b (anche denominato offset):

$w = [2, 3, 5, 5, 6, 10, 2, 2]$, $b=2$

Se la funzione di attivazione è una ReLU (Rectified Linear Unit) qual è l'output?



Scegli un'alternativa:

- ☐ a. 48
- ☐ b. Nessuna delle precedenti
- ☐ c. 22
- ☐ d. 28
- ☐ e. 24
- ☐ f. 40
- ☐ g. 26
- ☐ h. 42

Risposta: g, seguendo la formula bisogna fare

$$(1 * 2) + (0 * 3) + (1 * 5) + (1 * 5) + (0 * 6) + (1 * 10) + (1 * 2) + (0 * 2) + 2 = 26$$

Precisione e Recall

Precisione(i) = #predizioni corrette di i / #valori di pred assegnati ad i


Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

Recall(i) o Richiamo(i) = $\frac{\text{\#predizioni corrette di } i}{\text{\#valori di true di } i}$

Per problemi binari:

Precisione è il rapporto tra l'area della regione verde e l'ovale (freccia orizzontale)

Recupero è il rapporto tra l'area della regione verde e la regione di sinistra (freccia diagonale)



$$P(i) = \frac{TP(i)}{TP(i) + FP(i)}$$

$$R(i) = \frac{TP(i)}{TP(i) + FN(i)}$$

Se si hanno il vettore pred e gt:

$$P(i) = \frac{\text{\#(pred(j)==gt(j)==i)}}{\text{\#(pred(j)==i)}}$$

$$R(i) = \frac{\text{\#(pred(j)==gt(j)==i)}}{\text{\#(gt(j)==i)}}$$

22/02/2024

Precision(C): fraction of elements correctly classified for class C, out of all elements assigned to C

Recall(C): fraction of elements correctly classified for class C, out of all elements belonging to C

$$F1\text{-Score}(C): 2 \frac{Precision(C) * Recall(C)}{Precision(C) + Recall(C)}$$

Accuracy: correct classifications out of total samples

We have a dataset consisting of 20 samples containing 4 different classes (numbered 0 to 3). A classifier predicts the following classes for the 20 samples:

pr = [2, 0, 0, 3, 2, 0, 0, 0, 0, 2, 0, 2, 3, 1, 2, 3, 3, 2, 0, 3]

The expected class (ground truth) for each sample is represented by the following vector:

gt = [2, 3, 2, 0, 1, 3, 0, 3, 0, 3, 3, 2, 1, 1, 0, 0, 0, 3, 0, 3]

Which of the following statements is true?

Scegli un'alternativa:

- ☐ a. F1-Score of class 0 is greater than 0.5
- ☐ b. No precision value reaches the score of 1
- ☐ c. None of the answers are correct
- ☐ d. The recall of class 2 is lower than precision
- ☐ e. The accuracy is greater than 0.4
- ☐ f. The precision of class 2 is less than 0.4
- ☐ g. All recall values exceed 0.5
- ☐ h. The precision for class 0 is the lowest

La risposta corretta è: The precision of class 2 is less than 0.4

$$P(0) = \frac{3}{8}$$

$$R(0) = \frac{3}{7} < 0.5 \rightarrow g \text{ falsa}$$

$$P(1) = 1 \rightarrow b \text{ falsa}$$

$$R(1) = \frac{1}{3}$$

$$P(2) = \frac{2}{5} = 0.4 \rightarrow f \text{ falsa}$$

$$R(2) = \frac{2}{3} > P(2) \rightarrow d \text{ falsa}$$

$$P(3) = \frac{1}{5} \rightarrow h \text{ falsa}$$

$$R(3) = \frac{1}{7}$$

$$F1(0) = \frac{2}{5} < 0.5 \rightarrow a \text{ falsa}$$

$$\text{Acc} = \frac{7}{20} < 0.4 \rightarrow e \text{ falsa}$$

Risposta: c

11/09/2023

1.5 punti (-15% di penalità per risposta sbagliata)

- * Precisione(C) è la frazione di predizioni corrette rispetto a tutte le predizioni fatte per la classe C
- * Recall(C) è la frazione di predizioni corrette rispetto a tutti i punti che appartengono alla classe C

Vengono dati due vettori, y_pred , y_true , che contengono le predizioni effettuate da un classificatore e la ground truth, rispettivamente.

y_true : [B A A C A B B B C B]
 y_pred : [A A B A B C A B C C]

Quali sono precisione e richiamo per la classe A?

Scegli un'alternativa:

- ☐ a. Nessuna delle altre risposte è corretta
- ☐ b. Precisione: 0.5, Richiamo: 0.3333
- ☐ c. Precisione: 0.3333, Richiamo: 0.5
- ☐ d. Precisione: 0.3, Richiamo: 0.5
- ☐ e. Precisione: 0.3, Richiamo: 0.25
- ☐ f. Precisione: 0.3333, Richiamo: 0.2
- ☐ g. Precisione: 0.25, Richiamo: 0.3333
- ☐ h. Precisione: 0.2, Richiamo: 0.3333
- ☐ i. Precisione: 0.3333, Richiamo: 0.25

Attenzione vettori "invertiti" rispetto ai soliti esercizi. Ricordarsi che si parte da pred.

$$P(A) = \frac{1}{4}$$

$$R(A) = \frac{1}{3}$$

Risposta: g

26/01/2021

Teoria (Classificazione) (1 punto, -15% penalità per risposta sbagliata)


Precisione(C): frazione di elementi correttamente classificati nella classe C, tra tutti gli elementi assegnati alla classe C

Richiamo(C): frazione di elementi correttamente classificati nella classe C, tra tutti gli elementi appartenenti alla classe C

Accuratezza: frazione di elementi correttamente classificati, tra tutti gli elementi che sono stati classificati

Si vuole classificare con un albero di decisione un insieme di punti descritti da due variabili numeriche e rappresentabili in uno spazio bidimensionale.

La seguente figura mostra la suddivisione dello spazio bidimensionale in 5 regioni delimitate dai "decision boundary" definiti da un albero decisionale. Il colore di ciascuna regione corrisponde all'etichetta di classe assegnata dall'albero alla regione ("blu" per classe "triangolo", "arancione" per classe "cerchio").



L'insieme di test (test set) include 14 punti la cui etichetta di classe corretta è nota. Tali punti sono rappresentati nello spazio bidimensionale della figura precedente riportando per ciascun punto l'etichetta di classe corretta (rappresentata dal triangolo o dal cerchio).

Quale delle seguenti affermazioni è vera?

Scegli un'alternativa:

- ☐ a. Il richiamo per la classe "cerchio" è 6/7
- ☐ b. La precisione per la classe "triangolo" è 5/7
- ☐ c. La precisione per la classe "cerchio" è 6/7
- ☐ d. L'accuratezza è 11/13
- ☐ e. Il richiamo per la classe "triangolo" è 5/6

$$P(T) = 5/6$$

$$R(T) = 5/7$$

$$P(C) = 6/8$$

$$R(C) = 6/7$$

Risposta: a

29/01/24

1.5 punti (-15% di penalità per ogni risposta sbagliata)

Definizioni

Precisione(C): frazione degli elementi correttamente classificati nella classe C in tutti i fold, sugli elementi
Recall(C): frazione degli elementi correttamente classificati nella classe C in tutti i fold, sugli elementi app

Abbiamo a disposizione un dataset composto da 6000 campioni di cui 2400 appartenenti alla classe positiva (1) e 3600 alla classe negativa (0). Stiamo valutando un classificatore tramite stratified 3-fold cross-validation (mantenendo la distribuzione delle classi).

Il classificatore ottiene i seguenti risultati per ogni fold:

1. 600 predizioni corrette per la classe 1, 1000 predizioni corrette per la classe 0
2. 500 predizioni corrette per la classe 1, 900 predizioni corrette per la classe 0
3. 600 predizioni corrette per la classe 1, 900 predizioni corrette per la classe 0

Quale delle seguenti affermazioni riguardante la **classe 1** è corretta?

Scegli un'alternativa:

- ☐ a. La recall è più bassa di 0.4
- ☐ b. La precisione è più bassa della recall
- ☐ c. Nessuna risposta è corretta
- ☐ d. La recall in almeno un fold è inferiore a 0.5
- ☐ e. La precisione è più alta della recall
- ☐ f. La recall in almeno un fold supera 0.8
- ☐ g. La precisione è maggiore di 0.8
- ☐ h. La precision in almeno un fold è inferiore a 0.5

Risposta: b

corretto VS assegnati = prec. = $\frac{TP(C)}{TP(C) + FP(C)}$
corretto VS appartenenti = recall

$TP(C)$ = True positive della classe C

$FP(C)$ = false positive

recall = $\frac{TP(C)}{TP(C) + FN(C)}$ $FN(C)$ = false negative

TOT: 6K

C1: 2400

C2: 3600

$$TP(1) = 600 \cdot 2 + 500 = 1700$$

2400 in totale = 800 per fold

$$FN(1) = (800 - 600) \cdot 2 + (800 - 500) = 700$$

$$FP(1) = FN(0) = (1200 - 1000) + (1200 - 900) \cdot 2 = 800$$

$$P_z(1) = \frac{1700}{1700 + 800} = 0,68 \quad R(1) = \frac{1700}{1700 + 700} = 0,71$$

$$P_z(1) < R(1) \quad \checkmark$$

$$TP(0) = 1000 + 900 \cdot 2 = 2800$$

$$FP(0) = FN(1) = 700$$

$$FN(0) = 800$$

$$P_z(0) = \frac{2800}{2800 + 700} = 0,8 \quad R(0) = \frac{2800}{2800 + 800} = 0,78$$


23/01/2023

1 punto (penalità 15% per risposta sbagliata)

Precisione(X) è la frazione di predizioni corrette rispetto a tutte le predizioni fatte per la classe X
Richiamo(X) è la frazione di predizioni corrette rispetto a tutti i punti che appartengono alla classe X

Un classificatore basato su random forest e' stato addestrato con un dataset bidimensionale (features x_1 , x_2). Ciascun punto del dataset e' etichettato con un'etichetta di classe tra A, B, C (rispettivamente rappresentate come stella, croce, triangolo).

La seguente figura rappresenta un test set che e' stato utilizzato per validare il classificatore.



Le etichette assegnate del modello sono mostrate nella figura:

- Le aree con righe diagonali rappresentano zone in cui il modello predice classe A
- Le aree con dei pallini rappresentano zone in cui il modello predice classe B
- Le aree con righe orizzontali rappresentano zone in cui il modello predice classe C

Sulla base di queste informazioni, qual e' la precisione per la classe C e il richiamo per la classe B?

Scegli un'alternativa:

- ☐ a. precisione C: 1, richiamo B: 2/3
- ☐ b. precisione C: 3/4, richiamo B: 1
- ☐ c. precisione C: 1, richiamo B: 1
- ☐ d. precisione C: 2/3, richiamo B: 3/4
- ☐ e. Nessuna delle altre risposte e' corretta
- ☐ f. precisione C: 1, richiamo B: 3/4
- ☐ g. precisione C: 2/3 richiamo B: 1

pred = [A A A B B B B C C C C C C C]

gt = [A A A B B B B B C C C C C C]

$P(C) = 6/8 = 3/4$

$R(B) = 4/6 = 2/3$

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante


Risposta: e

Curva ROC

La curva ROC (Receiver Operating Characteristic) che plotta un grafico

- $x = \text{FPR} = \text{FP} / (\text{FP} + \text{TN})$ (False Positive Rate)
- $y = \text{TPR} = \text{TP} / (\text{TP} + \text{FN})$ (True Positive Rate)

In cui il punto (0,1) rappresenta la situazione ideale e la diagonale rappresenta un modello che predice l'etichetta di classe randomicamente. Il modello con l'area maggiore è quello che performa meglio.



24/04/23

2 punti (- 15% penalità per risposta sbagliata)

Il true positive rate (TPR) e il false positive rate (FPR) sono definiti come:

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$


Dove TP, TN, FP, FN sono rispettivamente true positives, true negatives, false positives, false negatives.

La curva ROC è una curva che permette di valutare le performance di un classificatore binario al variare della soglia discriminativa. Viene creato rappresentando il TPR (asse y) rispetto all'FPR (asse x), al variare della soglia.

Un classificatore binario (output: positive, negative) produce una probabilità a posteriori $x = P(\text{class} = \text{positive} | t)$ per ogni punto di test t . L'etichetta di classe viene assegnata in base a una soglia discriminativa applicata a x . I valori al di sopra della soglia vengono etichettati "positive", i valori al di sotto della soglia vengono etichettati "negative".

Il seguente grafico mostra la distribuzione delle probabilità a posteriori per un dataset di 200 record (100 record "positive", 100 record "negative").





Nello specifico, i 5 box nella parte alta della figura mostrano il numero cumulativo di record che appartengono alle classi positive (pos) e negative (neg), da $-\infty$ fino alla threshold definita dalla rispettiva linea verticale.

Per esempio, ci sono 33 record "positive" e 95 record "negative" che hanno $x \leq 0.5$.

Considerando la curva ROC per questo classificatore. Quali delle seguenti coppie di punti appartengono alla curva? (ogni punto viene fornito come coppia di coordinate (y, x)).

Quale delle seguenti affermazioni è vera?

Scegli un'alternativa:

- ☐ a. (92/100, 51/100), (99/100, 95/100)
- ☐ b. (51/141, 8/141), (5/162, 33/162)
- ☐ c. (99/194, 95/194), (92/143, 51/143)
- ☐ d. (49/141, 8/59), (100/129, 1)
- ☐ e. Le informazioni fornite sono insufficienti per rispondere alla domanda
- ☐ f. (51/100, 8/100), (5/100, 33/100)

Risposta: a

Tutti i valori da meno infinito fino al threshold sono negativi, se assegno quindi un valore positivo ho sbagliato, se invece è negativo allora è giusto.

Prendendo la curva blu (negativi) con $x=0.17$, prima di quel threshold ho predetto 1 vero e 5 falsi, quindi $TN = 5$ (i veri negativi) e $FN = 1$ (i negativi che ho sbagliato a predire).

Quindi:

- $TP = 100 - FN$
- $FP = 100 - TN$

(100 indica il numero di record positivi e negativi che sono 100 a testa, se avessi avuto 150 e 50 allora $TP = 150 - FN$ e $FP = 50 - TN$ e i punti ROC sarebbero stati (99/150, 95/50)).

Applicando le formule si trovano TPR e FPR e i 5 punti scritti sotto.

	0,17	0,33	0,50	0,67	0,83
TP	99	92	67	29	6
TN	5	49	95	100	100
FP	95	51	5	0	0
FN	1	8	33	71	94

	PUNTI	ROC	$\begin{matrix} y \\ x \end{matrix}$ (TPR, FPR)
(1)	(99/100,	95/100)	(4) $(\frac{29}{100}, 0)$
(2)	(92/100,	51/100)	(5) $(\frac{6}{100}, 0)$
(3)	(67/100,	5/100)	

11/09/2023


1.5 punti (-15% penalità per ogni risposta sbagliata)

Viene fornito un dataset composto da 2000 punti appartenenti a una classe positiva (+) o negativa (-). Il dataset è perfettamente bilanciato, con 1000 punti positivi e 1000 punti negativi.

Un classificatore addestrato sul dataset produce, per un punto x , una probabilità di appartenenza alla classe positiva $p(+|x)$. La probabilità di appartenenza alla classe negativa $p(-|x)$ può essere calcolata come $1 - p(+|x)$.

Un valore di soglia τ può essere definito per effettuare la predizione di una classe per un punto x . In particolare, se $p(+|x) > \tau$, il punto viene etichettato come positivo; altrimenti negativo.


La figura seguente mostra la distribuzione dei valori di $p(+|x)$ per i punti positivi e negativi. In particolare, i punti con ground truth negativa vengono mostrati nella distribuzione blu (a sinistra), mentre i punti con ground truth positiva vengono mostrati nella distribuzione arancione (a destra).




Quale delle seguenti figure mostra correttamente il numero di falsi negativi al variare di τ da 0 a 1?

Scegli un'alternativa:


☐ a.




☐ d.




☐ b.




☐ e.




☐ c.




☐ f.





☐ g.



☐ h.



Risposta: d



4. Clustering

K-Means

Algoritmo

1. Identifica i due centroidi iniziali
2. Calcola la distanza di Manhattan tra ogni punto e i due centroidi iniziali
3. Assegna ogni punto al centroide più vicino
4. Calcola i nuovi centroidi come la media (media aritmetica delle coordinate x e y) dei punti assegnati a ciascun cluster
5. Viene ripetuto dal punto 2) fino a che i centroidi smettono di spostarsi

03/07/24

Viene fornito un set di dati contenente 7 punti in 2 dimensioni (x_1 , x_2). Ogni punto è etichettato da A a G.


Si applica la clusterizzazione K-means con $K = 2$. La figura seguente rappresenta i 7 punti (punti blu) e le inizializzazioni dei due centroidi (stelle rosse). Ogni centroide è contrassegnato da un numero, rispettivamente il numero 0 e il numero 1.

Quali sono i nuovi centroidi calcolati dopo 1 iterazione dell'algoritmo K-means? Le risposte sono nel formato:

centroide0: (x_1 , x_2) - centroide1: (x_1 , x_2)

Per il calcolo di qualsiasi distanza, utilizzare la distanza Manhattan:

Graffa di chiusura in più o d'apertura mancante dove a e b sono due punti.



Scegli un'alternativa:

- ☐ a. 0: (2, 2.8) - 1: (1.5, 0.6)
- ☐ b. 0: (2, 2.8) - 1: (1, 1)
- ☐ c. 0: (2, 2) - 1: (1.5, 0.6)
- ☐ d. 0: (2, 2) - 1: (1.8, 0.5)
- ☐ e. 0: (2, 2.8) - 1: (1.5, 0.5)
- ☐ f. 0: (2, 2.6) - 1: (1.5, 0.5)
- ☐ g. Nessuna risposta è corretta
- ☐ h. 0: (2, 2) - 1: (1.5, 0.5)

Risposta: e

I punti assegnati sono: A(3,3), B(1,4), C(1,3), D(2,1), E(1,0), F(4,2), G(1,2).

I centroidi iniziali sono: 0(3,2), 1(2,0).

Per ogni punto calcoliamo la distanza di Manhattan da 1 e da 0:

A_0 = 1, A_1 = 4,

B_0 = 4, B_1 = 5,

C_0 = 3, C_1 = 4,

D_0 = 2, D_1 = 1,

E_0 = 4, E_1 = 1,

F_0 = 1, F_1 = 4,

G_0 = 2, G_1 = 3

Si assegna ogni punto al centroide più vicino {A,B,C,F,G} a 0 e {D, E} a 1.

Troviamo i centri di questi 2 nuovi cluster:

- Centroide 0: $((1+1+1+3+4)/5, (2+2+3+3+4)/5) = (2.0, 2.8)$
- Centroide 1: $((1+2)/2, (1+0)/2) = (1.5, 0.5)$

22/02/2024

2 punti (-15% di penalità per ogni risposta sbagliata)

Abbiamo a disposizione 5 punti con le seguenti coordinate (x, y) :

A (0, 0)

B (0, 4)

C (6, 2)

D (4, 2)

E (2, 4)

Vogliamo applicare il clustering di tipo K-Means per 2 iterazioni con i seguenti centroidi iniziali: (0, 0) e (5, 5). La metrica di distanza è: Graffa di chiusura in più o d'apertura mancante dove a e b sono due punti.

Quali cluster si ottengono?

Scegli un'alternativa:

- ☐ a. {A, E} {B, C, D}
- ☐ b. {A, B} {C, D, E}
- ☐ c. {A, B, E} {C, D}
- ☐ d. Nessuna risposta è corretta
- ☐ e. {D, E} {A, B, C}
- ☐ f. {A, E} {B, C, D}
- ☐ g. {D, A} {B, C, E}
- ☐ h. {A, B, D} {C, E}

Presuppongo distanza di Manhattan.

A_0 = 0, A_1 = 10,

B_0 = 4, B_1 = 6,

C_0 = 8, C_1 = 4,

D_0 = 6, D_1 = 4,

E_0 = 6, E_1 = 4

*Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante*

$\{A,B\}$ a 0 e $\{C, D, E\}$ a 1.

Risposta: b

Gerarchico

Clustering gerarchico

- **Agglomerativo**: partendo dai punti considerati come cluster individuali, ad ogni step viene unita la coppia di cluster più vicina, fino a che non ne rimane un solo cluster
- **Divisivo**: a partire da un unico cluster, esso viene diviso di volta in volta fino a quando ogni punto si trova in un cluster

Tipologie di approcci

- Single link o **MIN linkage**: viene scelta come distanza fra i due cluster la distanza minima fra le possibili coppie
- Complete linkage o **MAX linkage**: viene scelta come distanza fra i due cluster la distanza massima fra le possibili coppie
- Group average: la distanza fra i due cluster è rappresentata dalla media di tutte le distanze delle possibili coppie di gruppi

Clustering gerarchico **agglomerativo** con **MIN/MAX linkage**

Ogni punto è in un cluster separato

1. Prendo le **distanza minima** (sempre!) nella matrice delle distanze e unisco la coppia più vicina
2. Si aggiunge un elemento
 - a. Alla coppia formando una terna → distanza = distanza **minima/massima**
 - b. Ad ogni cluster singolo formando una coppia → distanza = distanza nella matrice
 - c. Si aggiunge l'elemento nel cluster a **distanza minima** (sempre!)

Si hanno 3 cluster: terna e 2 singole o due coppie e una singola, se l'esercizio chiede 3 cluster posso terminare l'esercizio, altrimenti ripeto passo 2.

21/02/23

1.5 punti (-15% penalità per risposta sbagliata)

La policy di MAX (complete) linkage prevede che la distanza fra due cluster X e Y sia calcolata come:

$$\text{dist}(X, Y) = \max_{x \in X, y \in Y} \text{dist}(x, y)$$

dove $\text{dist}(x, y)$ e' una distanza che puo' essere definita fra coppie di punti.

Per un dataset di 5 punti viene calcolata la seguente matrice di distanze.

	a	b	c	d	e
a	0	10	6	5	13
b	10	0	21	12	25
c	6	21	0	4	11
d	5	12	4	0	2
e	13	25	11	2	0

Si applica il clustering gerarchico agglomerativo per estrarre 3 cluster. Viene utilizzata la policy di "MAX linkage" (complete linkage).

Quali sono i 3 cluster ottenuti?

Scegli un'alternativa:

- ☐ a. {d, e}, {a}, {b, c}
- ☐ b. {c, e}, {a, d}, {b}
- ☐ c. {d, e}, {a, b}, {c}
- ☐ d. {b}, {d, e}, {a, c}
- ☐ e. {a, d}, {b, e}, {c}
- ☐ f. {a}, {b}, {c, d, e}
- ☐ g. Nessuna delle altre risposte e' corretta
- ☐ h. Non e' possibile rispondere alla domanda con le informazioni a disposizione

Risposta: d

	a	b	c	d	e
a	0	10	6	5	13
b	10	0	21	12	25
c	6	21	0	4	11
d	5	12	4	0	2
e	13	25	11	2	0

MAX linkage

$\{a\}, \{b\}, \{c\}, \{d\}, \{e\} \leftarrow \text{agglomerativo}$

linkage minima: $\{d, e\}$

$\{d, e\}, \{a\}, \{b\}, \{c\}$

aggiungo 1 elemento: $\{d, e, a\} = \max(5, 13) = 13$

$\{d, e, b\} = \max(12, 25) = 25$

$\{d, e, c\} = \max(4, 11) = 11$

$\{a, b\} = 10$

$\{a, c\} = 6$

$\{b, c\} = 21$

$\{d, e\}, \{a, c\}, \{b\}$

29/01/2024

Theory (1.5 points, -15% penalty for a wrong answer)

MAX Linkage policy states that the distance between two clusters is calculated as:

$$\text{dist}(X, Y) = \max(\text{dist}(x, y))$$

where $x \in X, y \in Y$ and $\text{dist}(x, y)$ is function that calculates the distance between two points.

Given the following matrix of distances between 5 points:

	a	b	c	d	e
a	0	9	7	10	13
b	9	0	6	16	4
c	7	6	0	8	6
d	10	16	8	0	17
e	13	4	6	17	0

How are the points aggregated to get 2 clusters if we use the previous policy in agglomerative hierarchical clustering?

Scegli un'alternativa:

- ☐ a. $\{a, d, b\} \{c, e\}$
- ☐ b. $\{b, e, c\} \{d, a\}$
- ☐ c. No answer is correct
- ☐ d. $\{d, b, c\} \{a, e\}$
- ☐ e. $\{b, e, d\} \{c, a\}$
- ☐ f. $\{a, e, c\} \{b, d\}$
- ☐ g. $\{a, b, c, d\} \{e\}$
- ☐ h. $\{b, e, c, d\} \{a\}$

Risposta: b

	a	b	c	d	e	
<u>max</u> linkage	a	0	9	7	10	13
	b	9	0	6	16	4
	c	7	6	0	8	6
	d	10	16	8	0	17
	e	13	4	6	17	0

$\{a\}, \{b\}, \{c\}, \{d\}, \{e\} \leftarrow$ agglomerativo

distance mine: $\{b, e\}$

$\{b, e\}, \{a\}, \{c\}, \{d\}$

aggiungo l'altro: $\{b, e, a\} = \max(9, 13) = 13$
 $\{b, e, c\} = \max(6, 6) = 6$
 $\{b, e, d\} = \max(16, 17) = 17$
 $\{a, c\} = 7$
 $\{a, d\} = 10$
 $\{c, d\} = 8$

$\{b, e, c\}, \{a, d\}$

24/04/2023

1 punto (-15% penalità per risposta sbagliata)

La metrica **MAX** (o complete linkage) nel clustering gerarchico agglomerativo prevede che:

Scegli un'alternativa:

- ☐ a. Nessuna delle risposte è corretta
- ☐ b. Due cluster C_1, C_2 vengono uniti se esiste una coppia di punti $p_1 \in C_1, p_2 \in C_2$ la cui distanza è la maggiore nella matrice delle distanze
- ☐ c. I primi due punti ad unirsi nel dendrogramma sono quelli più distanti tra loro
- ☐ d. Un cluster C verrà unito ad un singolo punto p se la massima distanza tra p ed i punti di C è la maggiore nella matrice delle distanze
- ☐ e. Un cluster C verrà unito ad un singolo punto p se la distanza tra p e C è quella massima nella matrice delle distanze
- ☐ f. I cluster ottenuti siano molto sensibili al rumore

Sia per MAX che per MIN si sceglie sempre la distanza **minore** nella matrice delle distanze.

Risposta: a

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

20/01/2025

1.5 points (-15% penalty for each wrong answer)

The single linkage policy states that the distance between two clusters X and Y is calculated as:

$$\text{dist}(X, Y) = \min(\text{dist}(x, y))$$

where $x \in X, y \in Y$ and $\text{dist}(x, y)$ is the Manhattan distance between two points $x = (x_1, \dots, x_n)$ and $y = (y_1, \dots, y_n)$, defined as $\text{dist}(x, y) = \sum_{i=1}^n |x_i - y_i|$.

Given the following points in 3 dimensions:

- A. 1,2,3
- B. 2,4,4
- C. 0,3,2
- D. 4,9,4
- E. 4,7,7

How are the points aggregated to get 2 clusters if we use the previous policy in agglomerative hierarchical clustering?

- ☐ a. {A, C, E, B} {D}
- ☐ b. {A, C, D} {B, E}
- ☐ c. {A} {D, E, C, B}
- ☐ d. No answer is correct
- ☒ e. {A, C, B} {D, E} ✓
- ☐ f. {A, C, E} {D, B}
- ☐ g. {A, B, C, D} {E}

Step 1: Calcolo di tutte le distanze di Manhattan a coppie

1. $\text{dist}(A, B) = |1 - 2| + |2 - 4| + |3 - 4| = 1 + 2 + 1 = 4$
2. $\text{dist}(A, C) = |1 - 0| + |2 - 3| + |3 - 2| = 1 + 1 + 1 = 3$
3. $\text{dist}(A, D) = |1 - 4| + |2 - 9| + |3 - 4| = 3 + 7 + 1 = 11$
4. $\text{dist}(A, E) = |1 - 4| + |2 - 7| + |3 - 7| = 3 + 5 + 4 = 12$
5. $\text{dist}(B, C) = |2 - 0| + |4 - 3| + |4 - 2| = 2 + 1 + 2 = 5$
6. $\text{dist}(B, D) = |2 - 4| + |4 - 9| + |4 - 4| = 2 + 5 + 0 = 7$
7. $\text{dist}(B, E) = |2 - 4| + |4 - 7| + |4 - 7| = 2 + 3 + 3 = 8$
8. $\text{dist}(C, D) = |0 - 4| + |3 - 9| + |2 - 4| = 4 + 6 + 2 = 12$
9. $\text{dist}(C, E) = |0 - 4| + |3 - 7| + |2 - 7| = 4 + 4 + 5 = 13$
10. $\text{dist}(D, E) = |4 - 4| + |9 - 7| + |4 - 7| = 0 + 2 + 3 = 5$

Step 2: Trova la coppia di punti più vicini tra loro e fai merge

Coppia di punti più vicini tra loro: (A, C) ($\text{dist}(A, C) = 3$)

Merge nel cluster $C1 = \{A, C\}$

Ricalcola le distanze da $C1$ agli altri punti utilizzando la policy single linkage.

$$\text{dist}(C1, B) = \min\{\text{dist}(A, B), \text{dist}(C, B)\} = \min\{4, 5\} = 4$$

$$\text{dist}(C1, D) = \min\{\text{dist}(A, D), \text{dist}(C, D)\} = \min\{11, 12\} = 11$$

$$\text{dist}(C1, E) = \min\{\text{dist}(A, E), \text{dist}(C, E)\} = \min\{12, 13\} = 12$$

La distanza minore è data da $\text{dist}(C1, B) = 4$

Merge di B con $C1$ in $C2 = \{A, C, B\}$

Calcola la distanza da $C2$ rispetto ai punti rimanenti (D, E):

$$\text{dist}(C2, D) = \min\{\text{dist}(A, D), \text{dist}(C, D), \text{dist}(B, D)\} = \min\{11, 12, 7\} = 7$$

$$\text{dist}(C2, E) = \min\{\text{dist}(A, E), \text{dist}(C, E), \text{dist}(B, E)\} = \min\{12, 13, 8\} = 8$$

Tuttavia, la distanza più piccola è $dist(D, E) = 5$, che è più piccola delle minime precedenti.

Merge nel cluster $C3 = \{D, E\}$

A questo punto, abbiamo esattamente 2 cluster ($k = 2$):

$$C2 = \{A, C, B\} \text{ e } C3 = \{D, E\}$$

DBSCAN

Richiede due variabili in ingresso Eps (epsilon) e MinPts (minpoints)


Per ogni punto, calcolare la distanza tra il punto e tutti quelli nelle vicinanze (matrice delle distanze), se #punti interni ad Eps

- $< \text{MinPts} \rightarrow \text{noise}$
- $= \text{MinPts} \rightarrow \text{border}$
- $> \text{MinPts} \rightarrow \text{core}$

Dopo aver eliminato i noise points, viene effettuato il clustering per tutti i punti rimanenti.

Per ogni punto core:

- Se il core point non appartiene ad un cluster, gliene viene assegnato uno nuovo
- Questo nuovo cluster viene assegnato anche a tutti i punti nel vicinato non ancora etichettati
- Se due cluster hanno $d < \text{Eps}$, vengono uniti



20/09/24

1.5 punto (-15% di penalità per ogni risposta sbagliata)

Distanza Manhattan: $L(A, B) = |x_a - x_b| + |y_a - y_b|$

Dato un dataset bidimensionale con 10 punti e viene applicato l'algoritmo DBSCAN con i parametri $Eps = 2.5$ e $MinPts = 4$.

I 7 core points (P1, P2, ..., P7) che sono stati individuati hanno le seguenti coordinate:

1. P1 (0, 0)
2. P2 (1, 1)
3. P3 (2, 4)
4. P4 (2, 2)
5. P5 (4, 3)
6. P6 (5, 4)
7. P7 (5, 5)

Quanti cluster vengono identificati dall'algoritmo DBSCAN utilizzando come metrica di distanza quella Manhattan?

Scegli un'alternativa:

- ☐ a. Più di 5 cluster
- ☐ b. 5 cluster
- ☐ c. 3 cluster
- ☐ d. 4 cluster
- ☐ e. Nessun cluster
- ☐ f. 1 cluster
- ☐ g. 2 cluster

Risposta: g

Costruisci la matrice delle distanze (di Manhattan) e seleziona tutti i punti distanti ≤ 2.5 (Eps).

Suggerimento: è una matrice simmetrica, basta anche disegnarne solo "metà".

	x	y	P1	P2	P3	P4	P5	P6	P7
P1	0	0	P1	0	(2)	6	4	7	9
P2	1	1	P2	0	4	(2)	5	7	8
P3	2	4	P3		0	(2)	3	3	4
P4	2	2	P4			0	3	5	6
P5	4	3	P5				0	(2)	3
P6	5	4	P6					0	(1)
P7	5	5	P7						0

$E = 2.5$

$\{P1, P2, P3, P4\}, \{P5, P6, P7\}$

23/01/23


1 punto (penalità 15% per risposta sbagliata)

La distanza di Manhattan (o cityblock) tra due punti a e $b \in \mathbb{R}^n$ viene definita come:

$$d(a, b) = \sum_{k=1}^n |a_k - b_k|$$

(k rappresenta la k -esima dimensione)

DBSCAN viene applicato al seguente dataset bidimensionale. Gli iperparametri utilizzati sono $\epsilon = 2.5$, $\text{minpoints} = 2$ (un punto viene considerato "core" se ha almeno minpoints punti entro un vicinato di raggio ϵ). Viene utilizzata la distanza di Manhattan per calcolare la distanza fra coppie di punti.



A ciascun punto viene assegnata una categoria fra noise, border e core.
Quali categorie vengono assegnate ai punti h, b, i?

Scegli un'alternativa:

- ☐ a. h core, b core, i border
- ☐ b. h border, b border, i border
- ☐ c. h border, b core, i core
- ☐ d. h core, b border, i border
- ☐ e. h noise, b border, i border
- ☐ f. Nessuna delle altre risposte e' corretta
- ☐ g. h noise, b core, i core
- ☐ h. h noise, b core, i border
- ☐ i. h border, b core, i border
- ☐ j. h core, b core, i core

Riposta: h

eps=2.5

minpoints = 2

#punti interni(h) = 1 < MinPts → h noise

#punti interni(b) = 3 > MinPts → b core

#punti interni(i) = 2 = MinPts → i border

09/02/2022

Teoria - 1.5 punti (penalità 15% per risposta sbagliata)

Quale delle seguenti affermazioni relative al clustering è corretta?

Scegli un'alternativa:

- ☐ a. il risultato dell'algoritmo DBSCAN può essere visualizzato tramite un dendrogramma
- ☐ b. utilizzando l'algoritmo k-means, il centroide di un cluster corrisponde sempre ad un punto appartenente a quel cluster
- ☐ c. Nell'algoritmo k-means, inizializzazioni diverse dei centroidi possono produrre come risultato cluster diversi
- ☐ d. nell'algoritmo DBSCAN, l'appartenenza di un punto a un determinato cluster è caratterizzata da un peso tra 0 e 1
- ☐ e. quando outliers e punti di rumore sono presenti nei dati, è più opportuno utilizzare l'algoritmo k-means rispetto a DBSCAN
- ☐ f. per ridurre il valore di SSE (sum of squared error) bisogna ridurre il valore di K dell'algoritmo k-means

Risposta: c

09/02/2022

Teoria - 1.5 punti (penalità 15% per risposta sbagliata)

Quale delle seguenti affermazioni relative al clustering **non** è corretta?

- ☐ (a) il clustering gerarchico richiede di poter calcolare distanze tra punti, tra punti e cluster e tra cluster
- ☐ (b) aumentando il valore di k nell'algoritmo k-means, normalmente si riduce il valore di SSE (sum of squared errors)
- ☐ (c) l'algoritmo DBSCAN non permette di specificare il numero di cluster desiderati
- ☐ (d) il risultato di un clustering gerarchico può essere visualizzato tramite un dendrogramma
- ☐ (e) nell'algoritmo DBSCAN, i clusters sono regioni ad alta densità di punti, separati da regioni a bassa densità
- ☐ (f) utilizzando l'algoritmo k-means, il centroide di un cluster corrisponde sempre ad un punto appartenente a quel cluster

Risposta: f

Silhouette

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- $a(i)$ = distanza media dell'oggetto i con tutti gli altri oggetti del suo cluster (sintesi della coesione)
- $b(i)$ = distanza media **minima** dell'oggetto i con i cluster di cui non fa parte (sintesi della separazione)

I valori di Silhouette variano fra -1 e +1, in cui +1 è il valore ideale.

16/06/2023

2 points (15% penalty for an incorrect answer)

A clustering can be represented as a set of n clusters $\{C_1, C_2, \dots, C_n\}$. Each cluster C_i is a set of points that have been assigned to the specific cluster. Given a point $x \in C_i$, its silhouette can be calculated as:

$$silh(x) = \frac{b(x) - a(x)}{\max\{b(x), a(x)\}}$$

Where:

- $a(x)$ is the average distance between x and all other points in C_i , i.e.

$$a(x) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, j \neq x} dist(j, x)$$

- $b(x)$ is the minimum distance between x and clusters to which x does not belong (the distance between a point and a cluster is calculated as the average distance bet

$$b(x) = \min_{C_k, k \neq i} \left\{ \frac{1}{|C_k|} \sum_{j \in C_k} dist(j, x) \right\}$$

($dist(w, z)$ is some distance between the points w and z .)

The following is a matrix of Manhattan distances between 6 2-dimensional points.

	a	b	c	d	e	f
a	0	9	9	10	10	7
b	9	0	2	5	9	12
c	9	2	0	7	9	12
d	10	5	7	0	4	7
e	10	9	9	4	0	3
f	7	12	12	7	3	0

A clustering algorithm was used on this dataset, obtaining 3 clusters (0, 1, 2). The cluster labels assigned to the 6 points are as follows:

A clustering algorithm was used on this dataset, obtaining 3 clusters (0, 1, 2). The cluster labels assigned to the 6 points are as follows:

a: 0
b: 0
c: 1
d: 1
e: 0
f: 2

Which are the silhouettes of points a and c?

The options are reported as (silhouette a, silhouette c) using 4 significant figures.

Scegli un'alternativa:

- ☐ a. (+0.0476, +0.2632)
- ☐ b. (-0.6111, -0.0952)
- ☐ c. (+0.2632, +0.0476)
- ☐ d. (-0.0952, -0.6111)
- ☐ e. (-0.0476, -0.2632)
- ☐ f. None of the options is correct.
- ☐ g. (+0.0952, +0.6111)
- ☐ h. (+0.6111, +0.0952)
- ☐ i. (-0.2632, -0.0476)

Risposta: i

Per la Silhouette di a, che appartiene al cluster 0

- $a(a) = \text{media della distanza dai punti in } 0 \text{ (quindi b, e)} = (9+10)/2 = 9.5$
- $b(a) = \text{distanza media minima tra a e gli altri cluster (quindi 1 e 2)}$
 $= \min((9+10)/2, 7/1) = 7$
- $s(a) = [b(a)-a(a)]/\max(a(a),b(a)) = (7-9.5)/9.5 = -0.2632$

Ripetiamo gli stessi passaggi per c, che appartiene al cluster 1

- $a(c) = 7/1 = 7$
- $b(c) = \min((9 + 2 + 9)/3, 12/1) = \min(20/3, 12) = 6.667$
- $s(b) = (6.667 - 7)/7 = -0.04761$

5. Gestione concorrenza

Anomalie

Tipologie di anomalie


- **Dirty read:** T2 legge il valore di x in uno stadio intermedio (prima che T1 faccia commit), T1 abortisce, x non è valido
- **Inconsistent read:** la transazione T1 legge x due volte, ma i due valori letti sono differenti perché T1 sta modificando x
- **Lost update:** T1, T2 accedono ad x e lo aggiornano contemporaneamente, una delle modifiche viene sovrascritta senza essere mai applicata o visibile
- **Ghost update:** T1 segue una query, ma T2 modifica (inserisce, aggiorna o elimina) in quel momento righe che rientrano nella query di T1

26/01/2021

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

1 punto (- 15% penalità per risposta errata)

Il seguente diagramma mostra l'esecuzione di due transazioni in parallelo in assenza di uno scheduler. Quale tipo di anomalia si verifica?



Notazione:

- $rX(o)$: Operazione di lettura da parte della transazione X dell'oggetto o
- $wX(o)$: Operazione di scrittura da parte della transazione X dell'oggetto o

Scegli un'alternativa:

- ☐ a. Ghost update (a)
- ☐ b. Dirty read
- ☐ c. Lost update
- ☐ d. Inconsistent read
- ☐ e. Ghost update (b)
- ☐ f. Non si verifica alcuna anomalia

Risposta: d

View serializzabile

Una schedule è **view serializzabile** se è **view equivalente** ad una schedule seriale arbitraria della stessa transazione.

View equivalente: due schedule sono view equivalenti se hanno gli stessi

- reads-from: $ri(x)$ reads-from $wj(x)$ se $wj(x)$ precede $ri(x)$ con $i \neq j$ e non c'è nessuna $wk(x)$ fra di esse
- final write: $wi(x)$ è una final write se essa è l'ultima scrittura di x nella schedule

Risolve il ghost update (a)

Come risolvere gli esercizi:

1. Individuare l'ultima scrittura per ogni x, y, z...
2. Collegare ogni lettura alla propria scrittura (es: ri con wi)
3. Individuare le precedenze R-W (es.: $wi(x) \dots rj(x)$ ALLORA $i \rightarrow j$)
4. Individuare le precedenze W-W (es.: $wi(x) \dots wj(x)$ ALLORA $i \rightarrow j$)
5. Trovare, **se esiste**, la sequenza seriale combinando le precedenze (es.: $i \rightarrow j \rightarrow k \rightarrow l$)

Nota: scartare le risposte che iniziano con una read (non legge nulla)

11/09/2023

Viene dato il seguente schedule di cinque transazioni:

$S = w1(y) \ r2(y) \ r1(y) \ w2(z) \ w2(z) \ r0(y) \ r2(z) \ r1(y) \ w0(z) \ w0(y)$

Dove $wn(o)$ indica un'operazione di scrittura da parte della transazione n verso l'oggetto o .

Analogamente, $ri(o)$ indica un'operazione di lettura da parte della transazione i verso l'oggetto o .

Quale delle seguenti affermazioni è vera?

Scegli un'alternativa:

- ☐ a. S è view serializable perchè è view equivalent allo schedule seriale $r0(y) \ w0(z) \ w0(y) \ w1(y) \ r1(y) \ r1(y) \ r2(y) \ w2(z) \ w2(z) \ r2(z)$
- ☐ b. S è view serializable perchè è view equivalent allo schedule seriale $r2(y) \ w2(z) \ w2(z) \ r2(z) \ w1(y) \ r1(y) \ r1(y) \ r0(y) \ w0(z) \ w0(y)$
- ☐ c. S è view serializable perchè è view equivalent allo schedule seriale $r2(y) \ w2(z) \ w2(z) \ r2(z) \ r0(y) \ w0(z) \ w0(y) \ w1(y) \ r1(y) \ r1(y)$
- ☐ d. S non è view serializable perchè non è view equivalent ad alcuno schedule seriale
- ☐ e. S è view serializable perchè è view equivalent allo schedule seriale $r0(y) \ w0(z) \ w0(y) \ r2(y) \ w2(z) \ w2(z) \ r2(z) \ w1(y) \ r1(y) \ r1(y)$
- ☐ f. S è view serializable perchè è view equivalent allo schedule seriale $w1(y) \ r1(y) \ r1(y) \ r0(y) \ w0(z) \ w0(y) \ r2(y) \ w2(z) \ w2(z) \ r2(z)$
- ☐ g. S è view serializable perchè è view equivalent allo schedule seriale $w1(y) \ r1(y) \ r1(y) \ r2(y) \ w2(z) \ w2(z) \ r2(z) \ r0(y) \ w0(z) \ w0(y)$

$1 \rightarrow 2$ R-W

$1 \rightarrow 0$ R-W

$2 \rightarrow 0$ W-W

$1 \rightarrow 0$ W-W

Perciò: $1 \rightarrow 2 \rightarrow 0$

Risposta: g

09/02/2022

Teoria - 1.5 punti (penalità 15% per risposta sbagliata)

Viene dato il seguente schedule di quattro transazioni:

$S = W4(Z) \ R2(Z) \ R1(X) \ W3(Y) \ R4(X) \ W2(X) \ R1(Y) \ W1(Y) \ R4(Y)$

Viene usata la seguente sintassi:

- $Ra(b)$ lettura da parte della transazione a dell'oggetto b
- $Wa(b)$ scrittura da parte della transazione a dell'oggetto b

Quale delle seguenti affermazioni è vera?

Scegli un'alternativa:

- ☐ a. S è view serializable perchè è view equivalent allo schedule $W3(Y) \ R1(Y) \ R1(X) \ W1(Y) \ W2(X) \ R2(Z) \ W4(Z) \ R4(X) \ R4(Y)$
- ☐ b. S è view serializable perchè è view equivalent allo schedule $W1(Y) \ R1(Y) \ R1(X) \ W3(Y) \ W4(Z) \ R4(X) \ R4(Y) \ W2(X) \ R2(Z)$
- ☐ c. S è view serializable perchè è view equivalent allo schedule $R1(X) \ W3(Y) \ R1(Y) \ R4(X) \ W2(X) \ W1(Y) \ R4(Y) \ W4(Z) \ R2(Z)$
- ☐ d. S è view serializable perchè è view equivalent allo schedule $W3(Y) \ R1(Y) \ R1(X) \ W1(Y) \ W4(Z) \ R4(X) \ R4(Y) \ W2(X) \ R2(Z)$
- ☐ e. S non è view serializable perchè non è view equivalent a nessuno schedule seriale
- ☐ f. S è view serializable perchè è view equivalent allo schedule $W3(Y) \ W4(Z) \ R4(X) \ R4(Y) \ R1(Y) \ R1(X) \ W1(Y) \ W2(X) \ R2(Z)$

$4 \rightarrow 2$

$3 \rightarrow 1$

$1 \rightarrow 4$

Realizzato da: *Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi*
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

$3 \rightarrow 1$

Perciò: $3 \rightarrow 1 \rightarrow 4 \rightarrow 2$

Risposta: d

Conflict serializzabile

Una schedule è **conflict serializzabile** (CSR) se è **conflict equivalente** ad una schedule seriale arbitraria delle stesse transazioni.

Conflict equivalente: due schedule sono conflict equivalenti se

- presentano gli stessi conflitti: A_i e A_j sono in conflitto se operano sullo stesso oggetto e una delle due azioni è una scrittura (RW, WR o WW)
- ogni coppia di azioni è nello stesso ordine in entrambe le schedule

Risolve il ghost update (a)


Come risolvere gli esercizi:

1. Individuare i conflitti
2. Generare il grafo dei conflitti
 - a. Nodo = transazione (es.: i, j, ...)
 - b. Arco = conflitto fra A_i e A_j e A_i precede A_j ($A_i \rightarrow A_j$)
3. Se il grafo dei conflitti è aciclico lo schedule è CSR
4. Se è CSR lo schedule conflict equivalente si trova percorrendo il grafo (percorso che collega tutti i nodi)

24/01/22

1.5 punti (penalità 15% per risposta sbagliata)

Il sistema di scheduling di un DBMS genera il grafo dei conflitti in figura.



Notazione:

T_n = Id della transazione n

$wn(x)$ = write eseguita dalla transazione n sull'oggetto x

$m(x)$ = read eseguita dalla transazione n sull'oggetto x

Quale delle seguenti affermazioni è corretta?

Scegli un'alternativa:

- ☐ a. nessuna delle affermazioni è corretta
- ☐ b. lo scheduling non è CSR. Uno schedule contenente il frammento „r1(x) w2(x) r4(x)„ può aver generato il grafo in figura
- ☐ c. lo scheduling non è CSR. Uno schedule contenente il frammento „r3(x) w1(x) r2(x)„ può aver generato il grafo in figura
- ☐ d. lo scheduling è CSR. Uno schedule contenente il frammento „r1(x) w2(x) r4(x)„ può aver generato il grafo in figura
- ☐ e. lo scheduling è CSR. Uno schedule contenente il frammento „r4(z) w5(z) w3(z)„ può aver generato il grafo in figura
- ☐ f. lo scheduling non è CSR. Uno schedule contenente il frammento „w3(y) w1(y) r2(y)„ **non** può aver generato il grafo in figura

Grafo ciclico → non CSR → b, c, f

$T1 \rightarrow T2 \rightarrow T3 \rightarrow T4 \rightarrow T1 \rightarrow \dots$

Risposta: b,c,f (nella soluzione vengono indicate tutte e 3)

29/01/2024

1.5 punti (15% di penalità per una risposta sbagliata)

Notazione:

$r_N(V)$: read dell'oggetto V da parte della transazione N

$w_N(V)$: write dell'oggetto V da parte della transazione N


Viene dato il seguente schedule di 3 transazioni:

$S = w_2(z) w_0(x) w_2(z) w_1(z) r_2(y) r_1(y) r_2(x) r_1(y) r_0(z) w_0(y)$

S è conflict serializable perchè è conflict equivalent allo schedule seriale:

Scegli un'alternativa:

- ☐ a. $w_0(x), r_0(z), w_0(y), w_1(z), r_1(y), r_1(y), w_2(z), w_2(z), r_2(y), r_2(x)$
- ☐ b. $w_2(z), w_2(z), r_2(y), r_2(x), w_0(x), r_0(z), w_0(y), w_1(z), r_1(y), r_1(y)$
- ☒ c. $w_0(x), r_0(z), w_0(y), w_2(z), w_2(z), r_2(y), r_2(x), w_1(z), r_1(y), r_1(y)$ ✗
- ☐ d. $w_1(z), r_1(y), r_1(y), w_2(z), w_2(z), r_2(y), r_2(x), w_0(x), r_0(z), w_0(y)$
- ☐ e. S non è conflict serializable
- ☐ f. $w_2(z), w_2(z), r_2(y), r_2(x), w_1(z), r_1(y), r_1(y), w_0(x), r_0(z), w_0(y)$
- ☐ g. $w_1(z), r_1(y), r_1(y), w_0(x), r_0(z), w_0(y), w_2(z), w_2(z), r_2(y), r_2(x)$



Risposta: e

22/02/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione:

$rN(V)$: read dell'oggetto V da parte della transazione N

$wN(V)$: write dell'oggetto V da parte della transazione N


Viene dato il seguente schedule S di 3 transazioni:

$W2(z), R1(y), W2(z), R2(y), R0(z), W1(x), R2(y), R2(x), R0(x), W1(x)$

Verificare se S è conflict serializable e, in caso affermativo, selezionare lo schedule seriale equivalente.

Scegli un'alternativa:

- ☒ a. $W2(z), W2(z), R2(y), R2(y), R2(x), R0(z), R0(x), R1(y), W1(x), W1(x)$ ✗
- ☐ b. $R1(y), W1(x), W1(x), R0(z), R0(x), W2(z), W2(z), R2(y), R2(y), R2(x)$
- ☐ c. $R1(y), W1(x), W1(x), W2(z), W2(z), R2(y), R2(y), R2(x), R0(z), R0(x)$
- ☐ d. S non è conflict serializable
- ☐ e. $R0(z), R0(x), W2(z), W2(z), R2(y), R2(y), R2(x), R1(y), W1(x), W1(x)$
- ☐ f. $W2(z), W2(z), R2(y), R2(y), R2(x), R1(y), W1(x), W1(x), R0(z), R0(x)$
- ☐ g. $R0(z), R0(x), R1(y), W1(x), W1(x), W2(z), W2(z), R2(y), R2(y), R2(x)$



Risposta: d

20/09/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione:

- T_n : Id della transazione n
- $B(T_n)$: Begin della transazione T_n
- $CK(T_a, T_b, \dots)$: checkpoint con transazioni $T_a, T_b, \dots$ non concluse
- $C(T_n)$: commit della transazione T_n
- $A(T_n)$: abort (rollback) della transazione T_n
- $Un(x)$: update eseguito dalla transazione T_n sull'oggetto x
- $In(x)$: insert eseguito dalla transazione T_n sull'oggetto x
- $Dn(x)$: delete eseguito dalla transazione T_n sull'oggetto x

Testo

Viene dato il seguente schedule S di 3 transazioni:

$W0(z), R1(z), R1(z), R1(z), W0(y), R1(y), W2(z), R1(x), R0(x), W1(y)$

Verificare se S è conflict serializable e, in caso affermativo, selezionare lo schedule seriale equivalente.

Scegli un'alternativa:

- ☒ a. $W0(z), W0(y), R0(x), R1(z), R1(z), R1(z), R1(y), R1(x), W1(y), W2(z)$ ✓
- ☐ b. S non è conflict serializable
- ☐ c. $W2(z), W0(z), W0(y), R0(x), R1(z), R1(z), R1(z), R1(y), R1(x), W1(y)$
- ☐ d. $R1(z), R1(z), R1(z), R1(y), R1(x), W1(y), W2(z), W0(z), W0(y), R0(x)$
- ☐ e. $R1(z), R1(z), R1(z), R1(y), R1(x), W1(y), W0(z), W0(y), R0(x), W2(z)$
- ☐ f. $W2(z), R1(z), R1(z), R1(z), R1(y), R1(x), W1(y), W0(z), W0(y), R0(x)$
- ☐ g. $W0(z), W0(y), R0(x), W2(z), R1(z), R1(z), R1(z), R1(y), R1(x), W1(y)$

0 → 1 → 2

Risposta: a

Locking gerarchico


Primitive

- Shared Lock (SL): lock di lettura (condiviso)
- eXclusive Lock (XL): lock di scrittura (esclusivo)
- Intention of Shared Lock (ISL): mostra l'intenzione di eseguire un SL su un oggetto presente in un nodo figlio
- Intention of eXclusive Lock (IXL): mostra l'intenzione di eseguire un XL su un oggetto presente in un nodo figlio
- Shared lock and Intention of eXclusive Lock (SIXL): effettua un SL dell'oggetto corrente e mostra l'intenzione di eseguire un XL lock per uno o più oggetti all'interno dei nodi figli

Request Protocol

- I lock vengono sempre concessi a partire dal nodo radice a scendere (padri → figli)
- I lock vengono rilasciati a partire dal nodo con un lock a granularità più dettagliata a salire (figli → padri)
- Per richiedere un SL o un ISL di un dato nodo, una transazione deve avere un ISL o un IXL sul suo nodo superiore

- Per richiedere un XL, IXL o SIXL su un nodo, una transazione deve avere un IXL o un SIXL sul suo nodo superiore
- Grafo delle precedenze per i lock




Compatibility matrix					
	Resource State				
Request	ISL	IXL	SL	SIXL	XL
ISL	Ok	Ok	Ok	Ok	No
IXL	Ok	Ok	No	No	No
SL	Ok	No	Ok	No	No
SIXL	Ok	No	No	No	No
XL	No	No	No	No	No

se avete proprio voglia di impararvi la matrice questo è il pattern che uso io per memorizzarla. SL-SL è circondato dal rosso, tutto quello sotto la grande piramide sotto SL è No, tutta la piccola piramide superiore è Ok.

09/09/2023, 26/01/2021

Teoria (Locking gerarchico) (1 punto, -15% penalità per risposta sbagliata)

La seguente immagine mostra (in rosso) i lock acquisiti da una transazione TA per una tabella a diversi livelli di granularità.



Una transazione TB deve (tra le altre operazioni) **modificare Tuple 1**. Quale delle seguenti affermazioni è vera?

- ☐ (a) La transazione TB non può prendere alcun lock che permetta la modifica di Tuple 1
- ☐ (b) La transazione TB può prendere IXL su Table, IXL su Fragment 1, IXL su Tuple 1
- ☐ (c) La transazione TB può prendere XL su Table, XL su Fragment 1, XL su Tuple 1
- ☐ (d) La transazione TB può prendere IXL su Table, XL su Fragment 1, XL su Tuple 1
- ☐ (e) La transazione TB può prendere ISL su Table, IXL su Fragment 1, XL su Tuple 1
- ☐ (f) La transazione TB può prendere SIXL su Table, IXL su Fragment 1, XL su Tuple 1

Risposta: f

La tupla T1 vuole essere modificata, quindi dovrà essere XL per forza (escludiamo la b che è IXL).

Se vogliamo usare XL su T1, fragment dovrà essere IXL o SIXL.


Andando per esclusione, sapendo che non si può avere un ISL o SL al sopra un XL o IXL, troviamo la f come risposta corretta.

03/07/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Denominazione
ISL: Intention of Shared Lock
SL: Shared Lock
SIXL: Shared Lock and Intention of eXclusive Lock
XL: eXclusive Lock

La seguente immagine mostra i lock acquisiti da una transazione TA per una tabella a diversi livelli di granularità nel formato Oggetto-Lock (se nessun lock è richiesto, Lock non è specificato).



Una transazione TB deve (tra le altre operazioni) leggere Field1. Quale delle seguenti affermazioni è vera?

Scegli un'alternativa:

- ☒ a. TB deve chiedere SL su Field1, ISL su Tuple1, ISL su Fragment1, ISL su Table1 ✓
- ☐ b. TB deve chiedere SL su Field1, SIXL su Tuple1, SIXL su Fragment1, SIXL su Table1
- ☐ c. TB deve chiedere ISL su Field1, ISL su Tuple1, ISL su Fragment1, ISL su Table1
- ☐ d. TB deve chiedere ISL su Field1, SL su Tuple1, SL su Fragment1, SL su Table1
- ☐ e. TB deve chiedere SIXL su Field1, ISL su Tuple1, ISL su Fragment1, ISL su Table1
- ☐ f. TB deve chiedere SIXL su Field1, ISL su Tuple1, ISL su Fragment1, ISL su Table1
- ☐ g. La transazione TB non può prendere alcun lock che permetta la lettura di Field1
- ☐ h. TB deve chiedere SL su Field1, SL su Tuple1, SL su Fragment1, SL su Table1

Lettura di Field 1 → a, b, h


Tupla 1: ISL o IXL → a

Risposta: a

21/02/2023

1 punto (penalità 15% per risposta sbagliata)

Il seguente albero mostra un sottoinsieme di una base dati con i diversi livelli di granularità (e.g. tabelle/frammenti/record). Per ogni nodo dell'albero, sono riportati i lock già acquisiti da altre transazioni tra [parentesi quadre].



Si tenga presente che, nell'albero, ciascun nodo eredita sempre un lock di livello almeno pari a quello del nodo padre, anche se non espressamente indicato nell'immagine.

Quale delle seguenti sequenze di lock può essere acquisita da una nuova transazione?

Scegli un'alternativa:

- ☐ a. ISL su A, SL su B, SL su E
- ☐ b. ISL su A, ISL su B, SL su D
- ☐ c. SIXL su A, ISL su B, ISL su E
- ☐ d. ISL su A, ISL su B, XL su E
- ☐ e. ISL su A, ISL su B, IXL su E
- ☐ f. IXL su A, IXL su B, IXL su E
- ☐ g. ISL su A, ISL su B, SL su E

D: IXL

Per richiedere un SL o un ISL di un dato nodo, una transazione deve avere un ISL o un IXL sul suo nodo superiore

E: SL $\rightarrow$ B: ISL (o IXL) $\rightarrow$ A: ISL (o IXL)

Risposta: g

6. Gestione ripristino

Warm Restart

- Lettura all'indietro del log fino all'ultimo checkpoint (CK)
- Creare 2 liste: UNDO = {Transazioni attive al checkpoint}, REDO = {Vuota}
- Lettura in avanti del log dal checkpoint
 - In UNDO vengono aggiunte le transazioni per cui viene trovato il begin record (B)
 - In REDO vengono spostate da UNDO le transazioni per cui viene trovato il commit record (C)
 - Le transazioni che hanno fatto abort (A) restano in UNDO

26/01/2021

Realizzato da: Samuele Maria Ferruggia, Matteo Di Gregorio, Elisabetta Anzaldi
Col contributo del riassunto del corso di Marchitelli Dario e Laera Sante

Domanda 1

Risposta non data

Punteggio max.:
1,00**Teoria (Recovery) (1 punto, -15% penalità per risposta sbagliata)**

Un file di log contiene al suo interno la seguente sequenza di operazioni:

B(T1) B(T2) U(T1) U(T1) I(T2) B(T3) A(T2) CK(T1,T3) I(T3) B(T4) D(T4) C(T1) B(T5) U(T5)
A(T4) **failure**

Notazione:

Ti: transazione i

B(Ti): Begin transazione

U(Ti): Update - I(Ti): Insert - D(Ti): Delete (gli altri parametri sono stati omessi per brevità)

CK(Ti, ..., Tj, ...): Checkpoint con lista delle transazioni attive

C(Ti): Commit transazione

A(Ti): Abort transazione

Quali sono le due liste Undo/Redo finali costruite dal processo di warm restart?

- ☐ (a) Undo {T3,T4, T5}, Redo {T1, T2}
- ☐ (b) Undo {T3, T4, T5}, Redo {T1}
- ☐ (c) Undo {T3, T5}, Redo {T1, T2, T4}
- ☐ (d) Undo {T1, T5}, Redo {T3, T4}
- ☐ (e) Undo {T1, T4}, Redo {T3, T5}
- ☐ (f) Undo {T3, T5}, Redo {T1, T4}

Risposta: b

Seguendo l'ordine delle transizioni, notiamo CK(T1,T3): il fallimento avviene dopo il CK le azioni precedenti su T1 e T3 sono state salvate e non sono da considerare.

Seguendo l'ordine abbiamo un Inserimento T3, l'inizio della transizione T4, una cancellazione T4, un commit su T1, un inizio di transizione T5, un aggiornamento su T5, un annullamento su T4.

Tutte queste operazioni vengono PERSE nel momento del fallimento.

Inserimenti, cancellazioni, aggiornamenti e abort vanno annullati (UNDO), mentre i commit vanno in REDO

11/09/2023

1 punto (15% di penalità per una risposta sbagliata)

È data la seguente sequenza di operazioni all'interno di un file di log:

```
B(T0) D0(o4) CK(T0) D0(o2) U0(o1) CK(T0) B(T1) I1(o0) Commit(T1) B(T2) Commit(T2) B(T3) B(T4) I3(o2) U4(o0) FAILURE
```

Notazione:

- Tn: Id della transazione n
- B(Tn): Begin della transazione Tn
- CK(Ta,Tb,...): checkpoint delle transazioni Ta, Tb, ...
- Commit(Tn): commit della transazione Tn
- Abort(Tn): abort (rollback) della transazione Tn
- Un(ox): update eseguito dalla transazione Tn sull'oggetto ox
- In(ox): insert eseguito dalla transazione Tn sull'oggetto ox
- Dn(ox): delete eseguito dalla transazione Tn sull'oggetto ox

Quali operazioni vengono eseguite per un warm restart?

Scegli un'alternativa:

- ☐ a. UNDO: [T0, T2, T4], REDO: [T1, T3]
- ☐ b. UNDO: [T0, T4], REDO: [T1, T2, T3]
- ☐ c. UNDO: [T0, T2, T4], REDO: [T3]
- ☐ d. UNDO: [T1, T2, T4], REDO: [T0, T3]
- ☐ e. UNDO: [T0, T2, T4], REDO: [T1]
- ☐ f. UNDO: [T0, T1, T3, T4], REDO: [T2]
- ☐ g. UNDO: [T0, T3, T4], REDO: [T1, T2]
- ☐ h. Nessuna delle altre operazioni è corretta

UNDO	REDO
T0	
T0, T1	
T0	T1
T0, T2	T1
T0	T1, T2
T0, T3	T1, T2
T0, T3, T4	T1, T2

Risposta: g

22/02/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione:

Tn: Id della transazione n

B(Tn): Begin della transazione Tn

CK(Ta,Tb,...): checkpoint con transazioni Ta, Tb, ... non concluse

C(Tn): commit della transazione Tn

A(Tn): abort (rollback) della transazione Tn

Un(x): update eseguito dalla transazione Tn sull'oggetto x

In(x): insert eseguito dalla transazione Tn sull'oggetto x

Dn(x): delete eseguito dalla transazione Tn sull'oggetto x

È data la seguente sequenza di operazioni all'interno di un file di log:

B(T1), U1(C), CK(T1), D1(B), B(T3), U3(A), B(T2), U2(B), C(T3), B(T0), C(T0), CK(T1,T2), I2(A), C(T1), U2(C), A(T2), FAILURE

Quali sono gli insiemi di UNDO e REDO finali per il warm restart?

Scegli un'alternativa:

- ☒ a. redo = { }, undo = {1, 2} ✖
- ☐ b. Nessuna delle precedenti
- ☐ c. redo = {1}, undo = {2}
- ☐ d. redo = {3}, undo = {2}
- ☐ e. redo = {1}, undo = {3}
- ☐ f. redo = {3}, undo = {1}
- ☐ g. redo = {2, 3}, undo = { }
- ☐ h. redo = {1, 2}, undo = { }

UNDO REDO

T1, T2

T2 T1

Risposta: c

03/07/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione

Tn: Id della transazione n
B(Tn): Begin della transazione Tn
CK(Ta,Tb,...): checkpoint con transazioni Ta, Tb, ... non concluse
C(Tn): commit della transazione Tn
A(Tn): abort (rollback) della transazione Tn
Un(x): update eseguito dalla transazione Tn sull'oggetto x
In(x): insert eseguito dalla transazione Tn sull'oggetto x
Dn(x): delete eseguito dalla transazione Tn sull'oggetto x

È data la seguente sequenza di operazioni all'interno di un file di log:

B(T2), I2(2), D2(3), U2(2), B(T0), I0(1), I2(0), B(T3), I3(1), C(T0), D3(1), CK(T2,T3), B(T1), U1(1), D1(2), C(T1), FAILURE

Quali sono gli insiemi di UNDO e REDO finali per il warm restart?

Scegli un'alternativa:

- ☐ a. REDO={1, 2}, UNDO={3}
- ☐ b. REDO={2}, UNDO={1, 3}
- ☒ c. REDO={1}, UNDO={2, 3} ✓
- ☐ d. Nessuna risposta è corretta
- ☐ e. REDO={1, 3}, UNDO={2}
- ☐ f. REDO={2, 3}, UNDO={1}
- ☐ g. REDO={2}, UNDO = { }
- ☐ h. REDO={3}, UNDO={1, 2}

Risposta: c

20/09/2024

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione

Tn: Id della transazione n
B(Tn): Begin della transazione Tn
CK(Ta,Tb,...): checkpoint con transazioni Ta, Tb, ... non concluse
C(Tn): commit della transazione Tn
A(Tn): abort (rollback) della transazione Tn
Un(x): update eseguito dalla transazione Tn sull'oggetto x
In(x): insert eseguito dalla transazione Tn sull'oggetto x
Dn(x): delete eseguito dalla transazione Tn sull'oggetto x

È data la seguente sequenza di operazioni all'interno di un file di log:

B(T3), C(T3), CK(), B(T1), U1(0), CK(T1), U1(2), CK(T1), B(T0), U0(2), CK(T0,T1), B(T2), D2(2), CK(T0,T1,T2), C(T2), C(T0), FAILURE

Quali sono gli insiemi di UNDO e REDO finali per il warm restart?

Scegli un'alternativa:


- ☐ a. REDO: {T0, T1}, UNDO: { }
- ☐ b. REDO: {T0}, UNDO: {T1}
- ☐ c. REDO: {T0}, UNDO: {T2}
- ☐ d. REDO: {T0, T1}, UNDO: {T2}
- ☒ e. REDO: {T0, T2}, UNDO: {T1} ✓
- ☐ f. REDO: {T1, T0}, UNDO: {T2}
- ☐ g. Nessuna risposta è corretta
- ☐ h. REDO: {T2}, UNDO: {T1}

UNDO REDO
T0, T1, T2
T0, T1 T2
T1 T0, T2
Risposta: e

7. DBMS distribuiti

2 phase commit

Il protocollo 2 phase commit consente di coordinare la commit di una **transazione distribuita** che ha un **Transaction Manager (TM)** e diversi **Resource Managers (RM)** che prendono parte alla transazione e hanno un log personale.
Il protocollo è diviso in 2 fasi.



09/02/2022

Teoria - 1 punto (penalità 15% per risposta sbagliata)

Si consideri la seguente esecuzione del protocollo 2-phase commit per i database distribuiti. Il Transaction Manager (TM) ha inviato un messaggio di global commit a tutti i Resource Managers (RMs) che partecipano al protocollo. Tuttavia allo scadere del timeout il TM non ha ancora ricevuto tutti i messaggi di acknowledgement (ACK) dai Resource Managers (RMs).

Quale delle seguenti affermazioni è corretta?

Scegli un'alternativa:

- ☐ a. il TM imposta un nuovo timeout e invia nuovamente il messaggio di global commit a tutti i RMs da cui non ha ricevuto ACK
- ☐ b. il TM definisce "global abort" come decisione globale per la transazione
- ☐ c. il TM invia un messaggio di global abort a tutti i RMs da cui non ha ricevuto ACK
- ☐ d. il TM conclude immediatamente il protocollo
- ☐ e. è ripetuta la fase 1 del protocollo 2-phase commit
- ☐ f. nessuna delle altre risposte è corretta

Risposta: a

8. MongoDB

Sintassi di base: find()

SQL	MongoDB
<code>SELECT attr2 WHERE attr1 = <value> FROM tabella</code>	<code>db.collezione.find({ attr1: <value> }, { _id: 0, attr2: 1 })</code>

Espressioni

attr: { \$<operatore> : <value> }

\$eq o :	=
\$ne	<>
\$gt, \$gte, \$lt, \$lte	>, >=, <, <=
\$in	= uno dei valori di un array
\$nin	<> tutti i valori di un array

Sintassi di base: aggregate()

```
db.collezione.aggregate([  
  { $studio1: { <studio1> } },  
  { $studio2: { <studio1> } },  
  ...  
])
```

SQL	MongoDB
<code>SELECT attr2, <SUM,AVG,...> AS aggreg1 WHERE attr1 = <value1> FROM tabella GROUP BY attr2 HAVING aggreg1 = <value2></code>	<code>db.collezione.aggregate([{ \$match: { attr1: <value1> } }, { \$group: { _id: "\$attr2", aggreg1: { <expr> } } }, { \$match: { aggreg1: <value2> } }])</code>

Ulteriori stadi della pipeline per aggregate

{ \$limit: <n> }	Seleziona i primi n elementi
{ \$sort: { key: <1,-1> } }	Riordina lo stream (1 = ASC, -1 = DESC) data una chiave
{ \$project: { <specifiche> } }	Aggiunge o rimuove field, permette di applicare operatori per modificare i dati

20/01/2025

1 point (-15% penalty for each wrong answer)

Documentation

match: Filters documents based on a specified query predicate. Matched documents are passed to the next pipeline stage. Syntax: { \$match: { <query predicate> } }

addFields: Adds new fields to documents. \$addFields outputs documents that contain all existing fields from the input documents and newly added fields. Syntax: { \$addFields: { <newField>: <expression>, ... } }

count: Counts and returns the total number of items in an array. Syntax: { \$size: <expression> }

Text

A streaming service stores its data in a MongoDB collection called movies. Each document represents a movie, including genre, release year, cast, ratings, and viewer statistics. The structure of a document is as follows:

```
{
  "title": "The Adventure Begins",
  "genre": "Adventure",
  "releaseYear": 2020,
  "cast": ["John Actor", "Jane Star"],
  "ratings": [
    { "user": "Alice", "rating": 5 },
    { "user": "Bob", "rating": 4 }
  ],
  "viewers": [
    { "location": "USA", "count": 150000 },
    { "location": "Canada", "count": 30000 }
  ]
}
```

Which query can be used to show only the titles of movies released after 2015 in the genre "Adventure," with an average rating of 4 or higher, and that had at least 200,000 total viewers overall?

☐ a.

```
db.movies.aggregate([
  {
    $match: {
      genre: "Adventure",
      releaseYear: { $gt: 2015 }
    }
  },
  {
    $project: {
      title: 1,
      averageRating: { $avg: "$ratings.rating" },
      totalViewers: { $sum: "$viewers.count" }
    }
  }
]);
```

☐ b.

```
db.movies.aggregate([
  {
    $addFields: {
      averageRating: { $avg: "$ratings.rating" },
      totalViewers: { $sum: "$viewers.count" }
    }
  },
  {
    $match: {
      genre: "Adventure",
      releaseYear: { $gt: 2015 },
      averageRating: { $gte: 4 },
      totalViewers: { $gte: 200000 }
    }
  },
  { $project: { title: 1, _id: 0 } }
]);
```

- ☐ c.

```
db.movies.aggregate([
  {
    $match: {
      genre: "Adventure",
      releaseYear: { $gt: 2015 },
      averageRating: { $gte: 4 },
      totalViewers: { $gte: 200000 }
    }
  },
  { $project: { title: 1, _id: 0 } }
]);
```
- ☐ d.

```
db.movies.aggregate([
  {
    $addFields: {
      averageRating: { $avg: "$ratings.rating" },
      totalViewers: { $sum: "$viewers.count" }
    }
  },
  {
    $match: {
      genre: "Adventure",
      releaseYear: { $gt: 2015 },
      averageRating: { $gte: 4 },
      totalViewers: { $gte: 200000 }
    }
  },
  { $project: { title: 1, _id: 0 } }
]);
```
- ☒ e.

```
db.movies.aggregate([
  {
    $match: {
      genre: "Adventure",
      releaseYear: { $gt: 2015 }
    }
  },
  {
    $addFields: {
      averageRating: { $avg: "$ratings.rating" },
      totalViewers: { $sum: "$viewers" }
    }
  },
  {
    $match: {
      averageRating: { $gte: 4 },
      totalViewers: { $gte: 200000 }
    }
  },
  { $project: { title: 1, _id: 0 } }
]);
```

 ✖
- ☐ f. No answer is correct

Query:

SELECT title

FROM movies

WHERE releaseYear >= 2015 AND genre = 'Adventure'

HAVING AVG(ratings.rating) >= 4 AND SUM(viewers.count) >= 200000

La prima operazione da effettuare è l'aggiunta dei campi mancanti per trovare il match richiesto.

Usiamo quindi `addFields` per calcolare la media delle recensioni e la somma degli spettatori. Fatto ciò è possibile procedere con la fase di `match`, soddisfacendo le condizioni richieste relative a genere, anno di pubblicazione, media delle recensioni e numero degli spettatori. Infine, è necessario specificare gli attributi da visualizzare mediante la clausola `project`.

Pertanto, la risposta corretta è la b.